

بسمه تعالی



دانشگاه صنعتی شریف

دانشکده مهندسی صنایع

درس: مبانی داده کاوی و کاربردهای آن

پیش‌بینی ریسک نکول مشتریان کارت اعتباری

گزارش نهایی پروژه درس

نگارش:

صبا یوسف‌زاده

سجاد سعیدی

استاد درس:

دکتر بستان‌آرا

بهار ۱۴۰۵

فهرست مطالب

۵	تقسیم وظایف اعضای گروه
۷	۱ مقدمه
۷	۱.۱ دامنه و محدودیت پژوهش
۸	۲ مرور ادبیات
۱۲	۱.۲ جمع‌بندی مطالعات پیشین و جایگاه پروژه حاضر
۱۲	۳ داده
۱۲	۱.۳ منبع داده و نحوه گردآوری
۱۳	۲.۳ ساختار متغیرها و متغیر هدف
۱۳	۳.۳ پاک‌سازی اولیه و ارزیابی کیفیت داده
۱۴	۴.۳ آمار توصیفی ویژگی‌های پیوسته
۱۵	۵.۳ تحلیل داده‌های پرت
۱۶	۶.۳ تحلیل متغیرهای جمعیت‌شناختی
۱۸	۷.۳ عدم تعادل کلاس هدف
۱۸	۸.۳ تحلیل همبستگی و الگوهای مالی
۲۱	۹.۳ پیش‌پردازش و مهندسی ویژگی
۲۱	۱.۹.۳ مقایسه روش‌های برخورد با مقادیر گمشده
۲۲	۲.۹.۳ مقایسه روش‌های مقیاس‌بندی
۲۳	۳.۹.۳ مهندسی و انتخاب ویژگی
۲۴	۴.۹.۳ مدیریت داده‌های پرت
۲۴	۵.۹.۳ مدیریت عدم تعادل کلاس‌ها
۲۵	۶.۹.۳ پیکربندی منتخب فاز پیش‌پردازش
۲۵	۷.۹.۳ تقسیم داده برای مدل‌سازی
۲۵	۴ مدل و نتایج
۲۶	۱.۴ تنظیمات آزمایش و فرایند آموزش
۲۶	۲.۴ معیارهای ارزیابی
۲۷	۳.۴ انتخاب الگوریتم‌ها

۴.۴	تنظیم ابرپارامترها	۲۸
۵.۴	اثر تنظیم ابرپارامترها	۳۲
۶.۴	مقایسه نهایی مدل ها	۳۴
۷.۴	تحلیل ماتریس درهم‌ریختگی مدل نهایی	۳۶
۸.۴	تحلیل توزیعی خطاهای مدل	۳۶
۱۸.۴	جمع‌بندی تحلیل خطاها	۴۲
۹.۴	اهمیت ویژگی‌ها و تفسیر مدل با SHAP	۴۲
۱۰.۴	مطالعه موردی خطاهای مدل با SHAP	۴۶
۱۱.۴	جمع‌بندی بخش مدل‌سازی و پاسخ به سؤال پژوهش	۴۷
۵	نتیجه‌گیری	۴۸
۱.۵	پاسخ به پرسش‌های پژوهش	۴۸
۲.۵	پیامدهای کاربردی	۴۹
۳.۵	محدودیت‌ها و مسیرهای ادامه کار	۴۹
فهرست مراجع		۵۱

فهرست جداول

۵	تقسیم وظایف و سهم اعضای گروه از فعالیت‌های پروژه.	۱
۱۱	جمع‌بندی مطالعات منتخب انجام‌شده روی مجموعه داده و شکاف‌های مرتبط با پروژه حاضر.	۲
۱۳	گروه‌های اصلی متغیرهای مجموعه داده.	۳
۱۴	خلاصه آمار توصیفی برخی ویژگی‌های پیوسته پس از پاک‌سازی اولیه.	۴
۲۲	مقایسه روش‌های جای‌گذاری مقادیر گم‌شده.	۵
۲۲	مقایسه روش‌های مقیاس‌بندی.	۶
۲۳	نتایج مهندسی و انتخاب ویژگی.	۷
۲۴	مقایسه روش‌های مدیریت داده‌های پرت.	۸
۲۴	مقایسه روش‌های مدیریت عدم تعادل کلاس.	۹
۲۵	خلاصه تصمیم‌های منتخب در فاز پیش‌پردازش.	۱۰
۲۹	فضای جست‌وجوی ابرپارامترها و منطق انتخاب مقادیر.	۱۱
۳۱	بهترین ابرپارامترهای مدل‌ها بر اساس RandomizedSearchCV.	۱۲
۳۲	مقایسه عملکرد مدل‌های پایه و تنظیم‌شده روی مجموعه آزمون.	۱۳
۳۵	مقایسه نهایی مدل‌های تنظیم‌شده روی مجموعه آزمون.	۱۴
۳۶	تعداد نمونه‌های چهار گروه حاصل از ماتریس درهم‌ریختگی مدل XGBoost.	۱۵
۳۸	میانگین ویژگی‌های منتخب در چهار گروه خطای مدل XGBoost.	۱۶
۴۳	ده ویژگی مهم مدل بر اساس میانگین قدر مطلق SHAP.	۱۷

فهرست تصاویر

۱	هیستوگرام و منحنی توزیع ویژگی‌های پیوسته پس از پاک‌سازی اولیه.	۱۵
۲	نمودار جعبه‌ای ویژگی‌های پیوسته برای شناسایی داده‌های پرت.	۱۶
۳	توزیع فراوانی ویژگی‌های دسته‌ای.	۱۷
۴	توزیع متغیرهای جمعیت‌شناختی به تفکیک وضعیت نکول.	۱۷
۵	توزیع متغیر هدف و نسبت عدم تعادل کلاس‌ها.	۱۸
۶	ماتریس همبستگی ویژگی‌های عددی.	۱۹
۷	توزیع سقف اعتبار به تفکیک وضعیت نکول.	۱۹
۸	تحلیل ارتباط ویژگی‌های مالی با متغیر هدف.	۲۰
۹	همبستگی زمانی و روند شش‌ماهه متغیرهای مالی.	۲۱
۱۰	ماتریس درهم‌ریختگی و منحنی‌های تشخیصی درخت تصمیم پس از تنظیم ابرپارامترها.	۳۲
۱۱	ماتریس درهم‌ریختگی و منحنی‌های ROC و Precision-Recall جنگل تصادفی.	۳۳
۱۲	ماتریس درهم‌ریختگی و منحنی‌های ROC و Precision-Recall مدل XGBoost.	۳۳
۱۳	ماتریس درهم‌ریختگی و منحنی‌های تشخیصی مدل LightGBM.	۳۴
۱۴	ماتریس درهم‌ریختگی و منحنی‌های تشخیصی رگرسیون لجستیک.	۳۴
۱۵	مقایسه جامع عملکرد مدل‌های تنظیم‌شده روی مجموعه آزمون.	۳۵
۱۶	مقایسه توزیع چگالی ویژگی‌های منتخب در چهار گروه TP، TN، FP و FN.	۳۷
۱۷	نمودارهای جعبه‌ای ویژگی‌های منتخب در چهار گروه خطای مدل XGBoost.	۴۰
۱۸	مقایسه مستقیم توزیع ویژگی‌های منتخب بین گروه‌های TP و FN.	۴۱
۱۹	نقشه حرارتی میانگین نرمال‌شده ویژگی‌های منتخب در چهار گروه خطای مدل.	۴۲
۲۰	نمودار Beeswarm مقادیر SHAP برای مدل XGBoost.	۴۴
۲۱	رتبه‌بندی سراسری ویژگی‌ها بر اساس میانگین قدر مطلق SHAP.	۴۵
۲۲	نمودارهای وابستگی SHAP برای بررسی اثرهای غیرخطی ویژگی‌های منتخب.	۴۶
۲۳	تحلیل محلی دو نمونه خطای مدل با نمودار آشنایی SHAP.	۴۷

تقسیم وظایف اعضای گروه

فعالیت‌های پروژه میان دو عضو گروه تقسیم شد، به گونه‌ای که هر عضو مسئولیت اصلی تعدادی از مراحل پروژه را از پیاده‌سازی و اجرای کد تا تحلیل نتایج و تدوین بخش متناظر گزارش بر عهده داشت. در عین حال، فعالیت‌هایی مانند مرور نهایی ادبیات، یکپارچه‌سازی نتایج، تدوین نتیجه‌گیری و بازبینی گزارش به صورت مشترک انجام شد.

جدول ۱: تقسیم وظایف و سهم اعضای گروه از فعالیت‌های پروژه.

فعالیت	مسئول	سهم از کل پروژه
درک و شناخت داده شامل بررسی ساختار مجموعه داده، آمار توصیفی، تحلیل اکتشافی، بررسی توزیع‌ها، همبستگی‌ها و تهیه کد و متن گزارش این بخش	یوسف‌زاده	15%
پیش‌پردازش داده شامل بررسی و مقایسه روش‌های مدیریت مقادیر گمشده، مقیاس‌بندی، مهندسی ویژگی، مدیریت داده‌های پرت و عدم تعادل کلاس‌ها و تهیه کد و متن گزارش این بخش	سعیدی	15%
پیاده‌سازی، تنظیم ابرپارامترها، ارزیابی و تحلیل کامل مدل‌های درخت تصمیم، جنگل تصادفی و رگرسیون لجستیک؛ شامل محاسبه معیارهای ارزیابی، ماتریس درهم‌ریختگی و منحنی‌های ROC و PR و تدوین متن گزارش مربوط	یوسف‌زاده	24%
پیاده‌سازی، تنظیم ابرپارامترها، ارزیابی و تحلیل کامل مدل‌های XGBoost و LightGBM؛ شامل محاسبه معیارهای ارزیابی، ماتریس درهم‌ریختگی و منحنی‌های ROC و PR و تدوین متن گزارش مربوط	سعیدی	16%
تحلیل تفسیرپذیری مدل نهایی با استفاده از SHAP، بررسی اهمیت جهانی ویژگی‌ها، تحلیل نمونه‌های محلی و تفسیر نتایج	سعیدی	8%
مرور و تکمیل ادبیات موضوع، یکپارچه‌سازی تحلیل‌های انجام‌شده، تدوین نتیجه‌گیری، بازبینی علمی و نگارشی و آماده‌سازی نهایی گزارش	یوسف‌زاده و سعیدی	22%
سهم نهایی یوسف‌زاده		50%
سهم نهایی سعیدی		50%

چکیده

پیش‌بینی نکول مشتریان یکی از مسائل مهم در مدیریت ریسک اعتباری است، زیرا شناسایی به‌موقع مشتریان پرریسک می‌تواند از تخصیص نامناسب اعتبار و زیان‌های مالی ناشی از عدم بازپرداخت جلوگیری کند. هدف این پروژه، توسعه و ارزیابی یک چارچوب داده‌کاوی برای پیش‌بینی نکول مشتریان کارت اعتباری با استفاده از اطلاعات جمعیت‌شناختی و سوابق رفتار مالی آن‌هاست. داده مورد استفاده شامل اطلاعات 30,000 مشتری و سوابق صورت‌حساب، پرداخت و تأخیر آن‌ها طی شش ماه متوالی است که پس از پاک‌سازی اولیه، 29,965 مشاهده در تحلیل به کار گرفته شد. ابتدا با تحلیل اکتشافی، توزیع ویژگی‌ها، داده‌های پرت، روابط میان متغیرها و وضعیت کلاس هدف بررسی شد که نشان داد حدود 22% مشتریان در کلاس نکول قرار دارند. سپس روش‌های مختلف جایگزینی مقادیر گم‌شده، مقیاس‌بندی، مدیریت داده‌های پرت، مهندسی ویژگی و مقابله با عدم تعادل کلاس‌ها به‌صورت مقایسه‌ای ارزیابی شدند. در مرحله مدل‌سازی، پنج الگوریتم رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی، XGBoost و LightGBM همراه با تنظیم ابرپارامترها و اعتبارسنجی متقابل بررسی شدند. نتایج نشان داد XGBoost با $ROC-AUC=0.7810$ ، $PR-AUC=0.5634$ ، فراخوانی 0.6237 و $F1=0.5354$ بهترین عملکرد کلی را در میان مدل‌های مقایسه‌شده داشته است. تحلیل خطاها و تفسیر مدل با SHAP نیز نشان داد سابقه تأخیر در پرداخت، به‌ویژه رفتار پرداخت در ماه‌های اخیر، در کنار سقف اعتبار و متغیرهای مرتبط با بدهی و پرداخت، نقش برجسته‌ای در تشخیص ریسک نکول دارند. در مجموع، یافته‌ها نشان می‌دهند ترکیب اطلاعات رفتاری و مالی مشتریان با مدل XGBoost می‌تواند چارچوب مؤثری برای شناسایی مشتریان پرریسک و پشتیبانی از تصمیم‌گیری در فرایند اعتبارسنجی فراهم کند.

۱. مقدمه

اعتباردهی به مشتریان یکی از تصمیم‌های مهم در نظام‌های مالی است؛ زیرا اعطای اعتبار به مشتری پرریسک می‌تواند زیان مستقیم ایجاد کند و از سوی دیگر، رد کردن یک مشتری خوش‌حساب نیز به معنای از دست رفتن فرصت درآمدی است. در چنین شرایطی، استفاده از داده‌های تاریخی مشتریان برای برآورد احتمال نکول می‌تواند تصمیم‌گیری را از یک قضاوت صرفاً تجربی به یک فرآیند مبتنی بر شواهد تبدیل کند. مسئله این پروژه به صورت یک مسئله دسته‌بندی دودویی تعریف شده است: آیا مشتری در دوره مورد نظر نکول خواهد کرد یا خیر؟

داده مورد استفاده، مجموعه Default of Credit Card Clients از مخزن UCI Machine Learning Repository است. این مجموعه داده از اطلاعات مشتریان کارت اعتباری در تایوان تشکیل شده و شامل مشخصات جمعیت‌شناختی، سقف اعتبار، وضعیت بازپرداخت، مبلغ صورت‌حساب و مبلغ پرداخت‌شده در شش ماه متوالی است [۱]. مطالعه اصلی مرتبط با این داده نیز با هدف مقایسه روش‌های داده‌کاوی برای پیش‌بینی احتمال نکول انجام شده است [۲]. در پروژه حاضر، علاوه بر مدل‌های پایه و درختی، روش‌های تقویتی و تحلیل تفسیرپذیری نیز بررسی شده‌اند. هدف اصلی پروژه، ساخت و مقایسه مدل‌هایی است که بتوانند مشتریان پرریسک را با دقت مناسب شناسایی کنند. پرسش‌های اصلی پروژه عبارت‌اند از:

- کدام الگوهای مالی و رفتاری بیشترین ارتباط را با نکول دارند؟
- کدام روش‌های پیش‌پردازش برای این داده عملکرد مناسب‌تری ایجاد می‌کنند؟
- کدام یک از مدل‌های پیاده‌سازی‌شده بهترین تعادل را میان Precision, Recall, F1, ROC-AUC و PR-AUC ایجاد می‌کند؟
- خطاهای مدل برتر در چه گروه‌هایی رخ می‌دهند و چه ویژگی‌هایی این خطاها را توضیح می‌دهند؟

۱.۱. دامنه و محدودیت پژوهش

دامنه این پروژه به پیش‌بینی نکول در ماه بعد با استفاده از اطلاعات موجود در همین مجموعه داده محدود است. داده‌ها مربوط به مشتریان کارت اعتباری در تایوان و رفتار مالی ثبت‌شده در سال 2005 هستند؛ بنابراین نتایج بدون اعتبارسنجی روی داده‌های جدیدتر یا جمعیت‌های دیگر نباید به همه بازارها و مؤسسات مالی تعمیم داده شوند. علاوه بر این، مجموعه داده تنها شش ماه سابقه پرداخت و صورت‌حساب را در اختیار می‌گذارد و متغیرهایی مانند درآمد، وضعیت اشتغال، شرایط کلان اقتصادی و سابقه اعتباری خارج از این دوره در آن وجود ندارند. در نتیجه، هدف پروژه کشف روابط پیش‌بینانه در داده موجود است و نه استنتاج رابطه علی میان ویژگی‌ها و نکول.

ساختار ادامه گزارش به این صورت است: ابتدا مرور مطالعات پیشین و جایگاه پروژه حاضر ارائه می‌شود. سپس منبع داده، ساختار متغیرها، تحلیل اکتشافی و آزمایش‌های پیش‌پردازش و مهندسی ویژگی تشریح می‌شوند. در بخش مدل و نتایج، پنج

الگوریتم همراه با فرایند تنظیم ابرپارامترها، معیارهای ارزیابی و مقایسه کمی بررسی می‌شوند. پس از انتخاب مدل برتر، تحلیل خطا و تفسیرپذیری با SHAP ارائه شده و در پایان، یافته‌های اصلی در ارتباط با پرسش‌های پژوهش جمع‌بندی و محدودیت‌ها و مسیرهای ادامه کار بیان می‌شوند.

۲. مرور ادبیات

پیش‌بینی نکول مشتریان کارت اعتباری یکی از مسائل شناخته‌شده در حوزه مدیریت ریسک و اعتبارسنجی است. مجموعه‌داده Default of Credit Card Clients به دلیل برخورداری هم‌زمان از اطلاعات جمعیت‌شناختی، سقف اعتبار و سابقه شش‌ماهه صورت‌حساب، پرداخت و تأخیر مشتریان، در مطالعات متعددی به عنوان یک مجموعه‌داده مرجع برای ارزیابی الگوریتم‌های یادگیری ماشین مورد استفاده قرار گرفته است. مرور پژوهش‌های انجام‌شده نشان می‌دهد که تمرکز مطالعات به تدریج از مقایسه ساده دقت الگوریتم‌های طبقه‌بندی به موضوعاتی مانند عدم تعادل کلاس‌ها، انتخاب معیارهای ارزیابی مناسب، روش‌های یادگیری گروهی، مهندسی ویژگی و در سال‌های اخیر تفسیرپذیری مدل‌ها گسترش یافته است.

یکی از نخستین و مهم‌ترین پژوهش‌ها بر این مجموعه‌داده توسط Yeh and Lien (2009) انجام شد [۲]. این مطالعه که مجموعه‌داده حاضر نیز در ارتباط با آن منتشر شده است، شش روش داده‌کاوی را برای پیش‌بینی نکول مشتریان مقایسه کرد. وجه تمایز اصلی این پژوهش آن بود که مسئله اعتبارسنجی را صرفاً به صورت یک طبقه‌بندی دودویی «نکول» و «عدم نکول» در نظر نگرفت؛ بلکه بر اهمیت برآورد احتمال نکول مشتری تأکید کرد. نویسندگان برای تقریب احتمال واقعی نکول از روشی با عنوان Sorting Smoothing Method استفاده کردند و عملکرد مدل‌هایی مانند رگرسیون لجستیک، تحلیل ممیزی، kNN، بیز ساده، درخت تصمیم و شبکه عصبی را مورد مقایسه قرار دادند. نتایج این مطالعه نشان داد شبکه عصبی مصنوعی در برآورد احتمال نکول عملکرد مناسبی دارد.

نقطه قوت پژوهش Yeh and Lien، ایجاد یک خط مبنای معتبر برای مقایسه چند خانواده متفاوت از روش‌های پیش‌بینی و همچنین توجه به احتمال نکول، به جای تکیه صرف بر برجسب نهایی، است. با این حال، این مطالعه پیش از گسترش الگوریتم‌های تقویتی مدرن مانند XGBoost و LightGBM انجام شده است. همچنین موضوعاتی مانند عدم تعادل کلاس‌ها، معیار PR-AUC، تحلیل هزینه خطاهای مختلف و روش‌های جدید تفسیرپذیری مدل در آن نقش محوری ندارند. بنابراین این مطالعه، اگرچه مبنای نظری مهمی برای مسئله فراهم می‌کند، به‌تنهایی برای ارزیابی روش‌های جدید کافی نیست.

در ادامه این مسیر، Hamori et al. (2018) به بررسی این پرسش پرداختند که آیا استفاده از مدل‌های پیچیده‌تر و شبکه‌های عصبی لزوماً به عملکرد بهتری در پیش‌بینی نکول منجر می‌شود یا خیر [۳]. آن‌ها سه روش یادگیری گروهی شامل Bagging، جنگل تصادفی و Boosting را با چند ساختار شبکه عصبی مقایسه کردند. نتایج نشان داد که Boosting می‌تواند از نظر عملکرد طبقه‌بندی حتی از برخی شبکه‌های عصبی بهتر عمل کند. همچنین عملکرد شبکه‌های عصبی به عواملی مانند تعداد لایه‌های پنهان، تابع فعال‌سازی و استفاده از Dropout وابسته بود.

مزیت مهم این پژوهش، مقایسه مستقیم یادگیری گروهی و یادگیری عمیق روی یک مسئله مشترک است و نتایج آن نشان می‌دهد که افزایش پیچیدگی مدل الزاماً به معنای افزایش قدرت پیش‌بینی نیست. این نتیجه به‌ویژه برای داده‌های جدولی اهمیت

دارد، زیرا مدل‌های مبتنی بر درخت و روش‌های گروهی اغلب می‌توانند با هزینه محاسباتی کمتر، عملکرد رقابتی ارائه کنند. با این حال، در این پژوهش نیز تمرکز اصلی بر قدرت طبقه‌بندی مدل‌ها قرار دارد و موضوعاتی مانند هزینه نامتقارن خطاها، انتخاب آستانه تصمیم و تفسیر دلایل پیش‌بینی مدل به‌صورت جامع بررسی نشده‌اند.

یکی از ویژگی‌های مهم مجموعه‌داده مورد استفاده در این پروژه، عدم تعادل متغیر هدف است؛ به‌گونه‌ای که تعداد مشتریان نکول‌کننده به‌مراتب کمتر از مشتریان غیرنکول‌کننده است. در چنین شرایطی، استفاده صرف از معیار دقت می‌تواند تصویری خوش‌بینانه از عملکرد مدل ایجاد کند؛ زیرا یک مدل ممکن است با پیش‌بینی مناسب کلاس اکثریت، دقت بالایی داشته باشد ولی بخش قابل‌توجهی از مشتریان پرریسک را شناسایی نکند.

Alam et al. (2020) این مسئله را به‌طور مشخص بررسی کردند و چند روش مختلف بازنمونه‌گیری برای مدیریت داده‌های نامتوازن را همراه با الگوریتم‌های یادگیری ماشین مقایسه نمودند [۴]. در این پژوهش، روش‌هایی مانند بیش‌نمونه‌گیری و کم‌نمونه‌گیری در کنار مدل‌های مختلف مورد ارزیابی قرار گرفتند و نتایج نشان داد که مدیریت عدم تعادل می‌تواند تأثیر محسوسی بر عملکرد مدل در شناسایی کلاس اقلیت داشته باشد. در مجموعه‌داده مربوط به مشتریان کارت اعتباری، ترکیب Gradient Boosted Decision Tree با k-means SMOTE از ترکیب‌های موفق گزارش‌شده بود.

یکی از نقاط قوت مطالعه Alam et al. آن است که مسئله عدم تعادل را به‌عنوان بخشی مستقل از فرایند مدل‌سازی در نظر گرفته و تنها به مقایسه طبقه‌بندها اکتفا نکرده است. استفاده از چند مجموعه‌داده نیز ارزیابی قابلیت تعمیم نتایج را نسبت به مطالعات تک‌دیتاستی تقویت می‌کند. با این حال، افزایش عملکرد پس از بازنمونه‌گیری الزاماً به این معنا نیست که همان مزیت در محیط واقعی و روی توزیع اصلی مشتریان نیز حفظ خواهد شد. از این رو، لازم است نتایج روش‌های متوازن‌سازی در کنار معیارهایی مانند Precision, Recall, F1 و PR-AUC تحلیل شوند.

در پژوهشی مرتبط، Chen and Zhang (2021) روشی مبتنی بر ترکیب k-means SMOTE و شبکه عصبی پس‌انتشار BP برای پیش‌بینی نکول ارائه کردند [۵]. در این رویکرد، ابتدا عدم تعادل کلاس‌ها با استفاده از k-means SMOTE کاهش یافت و سپس اهمیت ویژگی‌ها به کمک جنگل تصادفی استخراج شد. اطلاعات حاصل از اهمیت ویژگی‌ها نیز برای بهبود مقداردهی اولیه شبکه عصبی مورد استفاده قرار گرفت. نویسندگان گزارش کردند که استفاده از روش بازنمونه‌گیری موجب بهبود قابل‌توجه معیار AUC شده است.

نقطه قوت این مطالعه، ترکیب چند مرحله شامل مدیریت عدم تعادل، استخراج اهمیت ویژگی‌ها و مدل‌سازی شبکه عصبی در یک چارچوب واحد است. در مقابل، روش پیشنهادی دارای پیچیدگی بیشتری نسبت به یک مدل جدولی متعارف است و بخشی از عملکرد آن به نحوه تولید نمونه‌های مصنوعی وابسته است. همچنین خود نویسندگان اشاره می‌کنند که تأثیر استفاده از اهمیت ویژگی‌ها در بهبود شبکه عصبی محدود بوده است. بنابراین، استفاده از روش‌های بازنمونه‌گیری باید همراه با تحلیل دقیق اثر آن‌ها بر کلاس اقلیت و مقایسه با روش‌های ساده‌تر صورت گیرد.

در سال‌های اخیر، بخش دیگری از مطالعات تلاش کرده‌اند مقایسه میان مدل‌های آماری سنتی و الگوریتم‌های جدید یادگیری ماشین را با مجموعه گسترده‌تری از معیارهای ارزیابی انجام دهند. Bhandary and Ghosh (2025) شش روش شامل تحلیل ممیزی خطی، رگرسیون لجستیک، SVM، جنگل تصادفی، XGBoost و شبکه عصبی عمیق را روی همین مجموعه‌داده بررسی کردند [۶]. در این پژوهش، علاوه بر دقت، معیارهایی مانند حساسیت، ویژگی، Precision, G-mean, F1 و AUC نیز در

ارزیابی مدل‌ها به کار گرفته شدند.

نقطه قوت این پژوهش آن است که ارزیابی مدل را به یک معیار واحد محدود نمی‌کند و امکان مشاهده مصالحه میان معیارهای مختلف را فراهم می‌سازد. همچنین مقایسه مدل‌های آماری و مدل‌های یادگیری ماشین در یک چارچوب یکسان، دید مناسبی از تغییر عملکرد با افزایش پیچیدگی مدل ارائه می‌دهد. با این وجود، ساختار اصلی پژوهش همچنان بر مقایسه الگوریتم‌ها متمرکز است. با توجه به تعداد زیاد مطالعاتی که پیش‌تر روی این دیتاست مدل‌های مختلف را مقایسه کرده‌اند، صرف ایجاد یک جدول رتبه‌بندی جدید از الگوریتم‌ها به‌تنهایی نمی‌تواند همه ابعاد مسئله ریسک اعتباری را پوشش دهد.

مسئله دیگری که در مطالعات جدید بیشتر مورد توجه قرار گرفته، انتخاب معیار مناسب برای داده‌های نامتوازن است. (Sujon et al. (2025 عملکرد چند الگوریتم یادگیری ماشین را از منظر معیارهای مختلف و تحت شرایطی مانند عدم تعادل، تغییر آستانه تصمیم و نویز داده بررسی کردند [7]. آن‌ها مدل‌هایی شامل رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی، XGBoost و kNN را ارزیابی کردند و نشان دادند که معیارهایی مانند Accuracy و Precision در برخی سناریوهای نامتوازن ممکن است به‌تنهایی نماینده مناسبی از عملکرد مدل نباشند. در مقابل، معیارهایی مانند F1 و MCC در آزمایش‌های آن‌ها پایداری و توازن بیشتری نشان دادند.

مزیت اصلی این پژوهش آن است که پرسش را از «کدام مدل بهتر است؟» به «بر اساس کدام معیار می‌توان بهتر بودن مدل را قضاوت کرد؟» تغییر می‌دهد. این دیدگاه برای مسئله نکول اهمیت ویژه‌ای دارد؛ زیرا هزینه عدم شناسایی یک مشتری نکول‌کننده با هزینه اشتباه تشخیص دادن یک مشتری خوش‌حساب یکسان نیست. در عین حال، این پژوهش نیز محدودیت‌هایی دارد؛ از جمله اینکه هزینه مالی واقعی هر نوع خطا به‌طور مستقیم در معیارهای ارزیابی وارد نشده و بررسی آن عمدتاً در سطح شاخص‌های آماری انجام شده است.

هم‌زمان با افزایش قدرت پیش‌بینی مدل‌های پیچیده، موضوع تفسیرپذیری نیز در مطالعات اعتبارسنجی اهمیت بیشتری پیدا کرده است. در کاربردهای مالی، صرف دانستن اینکه یک مشتری به عنوان پریسک طبقه‌بندی شده کافی نیست؛ بلکه لازم است مشخص شود کدام ویژگی‌ها باعث شکل‌گیری تصمیم مدل شده‌اند. روش‌هایی مانند SHAP و LIME به همین منظور در پژوهش‌های جدید مورد استفاده قرار گرفته‌اند.

(Lin and Wang (2025 موضوع تفسیرپذیری را یک گام فراتر بردند و به جای ارائه تنها یک نمودار SHAP، پایداری توضیحات مدل را بررسی کردند [8]. آن‌ها تعداد زیادی مدل XGBoost با بذره‌های تصادفی متفاوت آموزش دادند و میزان ثبات رتبه ویژگی‌ها در تحلیل SHAP را اندازه‌گیری کردند. نتایج آن‌ها نشان داد که ویژگی‌های بسیار مهم مدل معمولاً از پایداری تفسیری بیشتری برخوردارند، در حالی که رتبه ویژگی‌های با اهمیت متوسط ممکن است بین اجراهای مختلف تغییر کند.

نقطه قوت این پژوهش آن است که استفاده از SHAP را به تولید یک نمودار اهمیت ویژگی محدود نمی‌کند و قابلیت اعتماد به توضیحات را نیز مورد پرسش قرار می‌دهد. این موضوع برای کاربردهای اعتباری اهمیت زیادی دارد، زیرا یک توضیح ناپایدار می‌تواند اعتماد تصمیم‌گیرنده به مدل را کاهش دهد. محدودیت مطالعه آن است که تمرکز اصلی بر یک خانواده مشخص از مدل‌ها و یک مجموعه داده قرار دارد و برای تعمیم نتیجه به مدل‌ها، جمعیت‌ها و محیط‌های اعتباری دیگر به مطالعات بیشتری نیاز است.

در کنار مسیرهای فوق، برخی پژوهش‌های جدید به موضوعاتی مانند عدالت الگوریتمی، حریم خصوصی و استفاده از

معماری‌های پیشرفته‌تر پرداخته‌اند. وجود ویژگی‌هایی مانند جنسیت، سن، سطح تحصیلات و وضعیت تأهل در این دیتاست امکان بررسی تفاوت عملکرد مدل میان گروه‌های جمعیتی را فراهم می‌کند. در مطالعات مرتبط با عدالت، این ویژگی‌ها به عنوان متغیرهای حساس یا بالقوه محافظت‌شده مورد بررسی قرار گرفته‌اند [۹]. اهمیت این مسیر در آن است که یک مدل اعتبارسنجی ممکن است از نظر معیارهای کلی عملکرد مطلوبی داشته باشد ولی نرخ خطا در گروه‌های مختلف جمعیتی یکسان نباشد. با این حال، ارزیابی عدالت به تعریف معیار مورد استفاده، ساختار جمعیت و زمینه تصمیم‌گیری وابسته است و نمی‌توان یک معیار واحد را برای تمام مسائل اعتباری مناسب دانست.

از سوی دیگر، وجود سابقه شش‌ماهه پرداخت و صورت‌حساب موجب شده است که مدل‌های ترتیبی، مدل‌های ترکیبی و معماری‌های پیشرفته نیز برای این مسئله مورد توجه قرار گیرند [۱۰]. اگرچه داده‌ها معمولاً به صورت یک جدول ثابت وارد مدل می‌شوند، متغیرهای PAY_0 تا PAY_6، BILL_AMT1 تا BILL_AMT6 و PAY_AMT1 تا PAY_AMT6 در ذات خود حاوی اطلاعات زمانی هستند. بنابراین استخراج ویژگی‌هایی مانند روند بدهی، میانگین پرداخت، نسبت پرداخت به صورت‌حساب، شدت و تداوم تأخیر می‌تواند بخشی از این ساختار زمانی را در اختیار مدل قرار دهد. در عین حال، استفاده از یک معماری پیچیده‌تر تنها زمانی توجیه‌پذیر است که نسبت به مدل‌های قوی داده‌های جدولی، بهبود قابل‌اعتماد و قابل‌تفسیر ایجاد کند.

جدول ۲: جمع‌بندی مطالعات منتخب انجام‌شده روی مجموعه داده و شکاف‌های مرتبط با پروژه حاضر.

مطالعه	نقطه قوت	محدودیت یا شکاف مرتبط
Yeh & Lien (2009) [۲]	توجه به احتمال نکول به جای صرفاً برچسب دودویی و ایجاد خط مبنای اولیه	عدم پوشش مدل‌های تقویتی جدید، عدم تعادل کلاس و ابزارهای جدید تفسیرپذیری
Hamori et al. (2018) [۳]	نشان دادن اینکه پیچیدگی بیشتر الزاماً به عملکرد بهتر منجر نمی‌شود	تمرکز محدودتر بر هزینه خطا، آستانه تصمیم و تفسیر مدل
Alam et al. (2020) [۴]	مقایسه چند روش متوازن‌سازی و بررسی اثر آن‌ها روی کلاس اقلیت	فاصله میان بهبود معیارهای آماری و هزینه واقعی تصمیم اعتباری
Chen & Zhang (2021) [۵]	ترکیب باز نمونه‌گیری، اهمیت ویژگی و مدل غیرخطی	وابستگی نتیجه به داده مصنوعی و پیچیدگی بیشتر چارچوب
Bhandary & Ghosh (2025) [۶]	استفاده از چند معیار ارزیابی و مقایسه مدل‌های ساده و پیچیده	تداوم تمرکز بر رتبه‌بندی مدل‌ها در یک دیتاست واحد
Sujon et al. (2025) [۷]	تحلیل حساسیت معیارها به عدم تعادل، آستانه و نویز	عدم ورود مستقیم هزینه مالی واقعی خطاها به تصمیم نهایی
Lin & Wang (2025) [۸]	بررسی اعتمادپذیری توضیحات در چند اجرای مدل	تمرکز بر یک خانواده مدل و یک مجموعه داده

جدول ۲ نشان می‌دهد که مسیر پژوهش روی این مجموعه داده از «مقایسه صرف الگوریتم‌ها» به سمت پرسش‌های

واقع‌گرایانه‌تر درباره کلاس اقلیت، معیار مناسب، هزینه خطا و قابلیت توضیح مدل حرکت کرده است. بر همین اساس، ارزش تحلیلی پروژه حاضر نه در معرفی یک الگوریتم جدید، بلکه در کنار هم قرار دادن مقایسه پیش‌پردازش، تنظیم مدل، تحلیل خطا و تفسیر ویژگی‌ها در یک جریان واحد قرار دارد.

۱.۲. جمع‌بندی مطالعات پیشین و جایگاه پروژه حاضر

جمع‌بندی پژوهش‌های پیشین نشان می‌دهد که روند مطالعات انجام‌شده روی این مجموعه داده را می‌توان در چند مرحله کلی مشاهده کرد. مطالعات اولیه عمدتاً بر مقایسه الگوریتم‌ها و افزایش دقت پیش‌بینی متمرکز بودند. در مرحله بعد، مسئله عدم تعادل کلاس و روش‌های بازنمونه‌گیری مورد توجه قرار گرفت. در پژوهش‌های جدیدتر نیز انتخاب معیار مناسب، تحلیل آستانه تصمیم و تفسیرپذیری مدل اهمیت بیشتری پیدا کرده‌اند. بنابراین، ارزیابی یک سامانه پیش‌بینی نکول تنها با گزارش Accuracy نمی‌تواند تصویر کاملی از کیفیت مدل ارائه دهد.

بر این اساس، هدف پروژه حاضر ارائه یک الگوریتم کاملاً جدید یا اثبات برتری مطلق یک خانواده از مدل‌ها نیست؛ بلکه تلاش شده است مراحل مختلف مسئله در قالب یک فرایند تحلیلی یکپارچه‌تر بررسی شوند. ابتدا ساختار آماری و الگوهای موجود در داده از طریق تحلیل اکتشافی مطالعه شده و سپس روش‌های مختلف پیش‌پردازش شامل مقیاس‌بندی، مدیریت داده‌های پرت، مهندسی ویژگی و مدیریت عدم تعادل کلاس‌ها به صورت مقایسه‌ای ارزیابی شده‌اند.

در مرحله مدل‌سازی نیز پنج الگوریتم رگرسیون لجستیک، درخت تصمیم، جنگل تصادفی، XGBoost و LightGBM مورد بررسی قرار گرفته‌اند و تنظیم ابرپارامترهای مدل‌ها با استفاده از اعتبارسنجی متقابل انجام شده است. با توجه به نامتوازن بودن متغیر هدف، ارزیابی به Accuracy محدود نشده و معیارهای Precision، Recall، F1، ROC-AUC و PR-AUC نیز در مقایسه مدل‌ها مورد استفاده قرار گرفته‌اند.

در نهایت، پس از انتخاب مدل برتر، نمونه‌های TP، TN، FP و FN به طور جداگانه تحلیل شده‌اند تا مشخص شود مدل در چه نوع مشتریانی بیشتر دچار خطا می‌شود. همچنین از SHAP برای بررسی اهمیت و جهت اثر ویژگی‌ها بر پیش‌بینی مدل استفاده شده است. به این ترتیب، جایگاه پروژه حاضر در امتداد پژوهش‌هایی قرار می‌گیرد که به جای تکیه صرف بر یک عدد نهایی، مقایسه مدل‌ها، مسئله عدم تعادل کلاس، تحلیل خطا و تفسیر رفتار مدل را به صورت هم‌زمان مورد توجه قرار می‌دهند.

۳. داده

۱.۳. منبع داده و نحوه گردآوری

داده‌های مورد استفاده در این پروژه از مجموعه داده Default of Credit Card Clients در مخزن UCI Machine Learning Repository تهیه شده‌اند [۱]. این مجموعه داده توسط I-Cheng Yeh ارائه شده و با شناسه Dataset 350 و DOI: 10.24432/C55S3H منتشر شده است. داده شامل اطلاعات 30,000 مشتری کارت اعتباری در تایوان است و هدف آن پیش‌بینی نکول پرداخت مشتری در ماه بعد بر مبنای اطلاعات موجود تا پایان دوره مشاهده است.

اطلاعات مالی مشتریان در یک بازه شش ماهه، از آوریل تا سپتامبر 2005، ثبت شده‌اند. برای هر مشتری، وضعیت بازپرداخت در هر ماه، مبلغ صورت حساب و مبلغ پرداخت شده در همان دوره در اختیار است. در کنار آن، سقف اعتبار و چند ویژگی جمعیت‌شناختی نیز ثبت شده‌اند. صفحه رسمی UCI محل جغرافیایی، دوره زمانی و ساختار متغیرها را مشخص می‌کند، اما جزئیات نهادی فرایند نمونه‌گیری، نام مؤسسه مالی و سازوکار دقیق استخراج رکوردها را تشریح نمی‌کند؛ بنابراین در این گزارش درباره این موارد فرض اضافه‌ای مطرح نشده است.

۲.۳. ساختار متغیرها و متغیر هدف

هر سطر داده متناظر با یک مشتری است. فایل اصلی علاوه بر شناسه ID، دارای 23 ویژگی توضیحی و یک متغیر هدف دودویی است. گروه‌های اصلی متغیرها در جدول ۳ خلاصه شده‌اند.

جدول ۳: گروه‌های اصلی متغیرهای مجموعه داده.

متغیرها	گروه	توضیح
LIMIT_BAL	سقف اعتبار	میزان اعتبار تخصیص یافته به مشتری
SEX, EDUCATION, MARRIAGE, AGE	جمعیت‌شناختی	جنسیت، سطح تحصیلات، وضعیت تأهل و سن مشتری
PAY_i	وضعیت بازپرداخت	وضعیت و میزان تأخیر بازپرداخت در ماه‌های متوالی
BILL_AMT i	صورت حساب	مبلغ صورت حساب‌های ماهانه در دوره شش ماهه
PAY_AMT i	پرداخت	مبلغ پرداخت شده توسط مشتری در ماه‌های متناظر
Default	متغیر هدف	1: نکول در ماه بعد؛ 0: عدم نکول

بنابراین مسئله این پروژه از نوع طبقه‌بندی دودویی است. اگرچه اطلاعات شش ماه گذشته به صورت ستون‌های جداگانه در جدول ذخیره شده‌اند، این ستون‌ها در عمل ساختاری زمانی از رفتار مشتری را بازنمایی می‌کنند. به همین دلیل، علاوه بر استفاده از ویژگی‌های خام، در ادامه ویژگی‌هایی برای خلاصه‌سازی سطح بدهی، پرداخت و نسبت استفاده از اعتبار ساخته شد.

۳.۳. پاک‌سازی اولیه و ارزیابی کیفیت داده

پیش از تحلیل، کیفیت داده از نظر مقادیر گمشده، کدهای غیرمعارف، تکرار رکوردها و متغیرهای فاقد ارزش پیش‌بینی بررسی شد. متغیر شناسه مشتری^۱ تنها نقش شناسایی رکورد را دارد و به همین دلیل از ماتریس ویژگی‌ها حذف شد. سپس کدهای نادر و خارج از دسته‌بندی اصلی در متغیر EDUCATION، یعنی مقادیر 0، 5 و 6، در گروه «سایر» ادغام شدند و مقدار 0 در MARRIAGE نیز به گروه «سایر» منتقل شد. این اقدام باعث شد دسته‌های کیفی پیش از مدل‌سازی تعریف یکدست‌تری داشته باشند.

^۱ID

در نوت‌بوک، بررسی تکرار پس از حذف شناسه انجام شد و 35 ردیف با ترکیب کاملاً یکسان ویژگی‌ها شناسایی و حذف شدند؛ در نتیجه تعداد مشاهدات مورد استفاده در ادامه تحلیل از 30,000 به 29,965 کاهش یافت. همچنین هیچ مقدار گمشده واقعی در داده نهایی مشاهده نشد. بنابراین مسئله اصلی کیفیت داده در این مجموعه نه داده گمشده، بلکه چولگی شدید متغیرهای پولی، وجود مقادیر پرت و برخی کدهای دسته‌ای غیرمتعارف بود که در مراحل بعد به‌صورت مجزا بررسی شدند.

۴.۳. آمار توصیفی ویژگی‌های پیوسته


برای شناخت شکل توزیع متغیرهای عددی، علاوه بر میانگین و انحراف معیار، چارک اول، میانه، چارک سوم، کمینه، بیشینه و چولگی نیز محاسبه شد. جدول ۴ نمونه‌ای از این آمار را برای چند ویژگی مهم نشان می‌دهد.

جدول ۴: خلاصه آمار توصیفی برخی ویژگی‌های پیوسته پس از پاک‌سازی اولیه.

ویژگی	میانگین	انحراف معیار	کمینه	چارک اول	میانه	چارک سوم	بیشینه	چولگی
AGE	35.49	9.22	21	28	34	41	79	0.73
LIMIT_BAL	167442.01	129760.14	10000	50000	140000	240000	1000000	0.99
BILL_AMT1	51283.01	73658.13	-165580	3595	22438	67260	964511	2.66
PAY_AMT1	5670.10	16571.85	0	1000	2102	5008	873552	14.66
PAY_AMT2	5927.98	23053.46	0	850	2010	5000	1684259	30.44

برای متغیر AGE نزدیکی میانگین و میانه و چولگی 0.73 نشان می‌دهد توزیع نسبتاً متعادل‌تر از متغیرهای مالی است. در مقابل، در BILL_AMT1 و به‌ویژه PAY_AMT1 و PAY_AMT2 فاصله زیاد میان میانگین و میانه و همچنین بیشینه‌های بسیار بزرگ، وجود دنباله راست بلند را نشان می‌دهد. برای مثال، میانه PAY_AMT2 تنها 2010 است، در حالی که مقدار بیشینه آن به 1,684,259 می‌رسد و ضریب چولگی آن 30.44 است. چنین الگویی توضیح می‌دهد چرا بررسی داده‌های پرت و روش‌های مقیاس‌بندی مقاوم در این پروژه ضروری بوده است.


شکل ۱ تصویر بصری همین الگوها را ارائه می‌کند. در متغیرهای BILL_AMT مقادیر منفی نیز مشاهده می‌شود که می‌تواند با مانده بستانکار یا تعدیلات حساب سازگار باشد؛ بنابراین این مقادیر صرفاً به دلیل منفی بودن به عنوان خطای داده حذف نشدند. در مقابل، متغیرهای PAY_AMT دارای دنباله راست بسیار بلند هستند و تعداد اندکی پرداخت بسیار بزرگ، میانگین و واریانس را به‌شدت تحت تأثیر قرار می‌دهند.



شکل ۱: هیستوگرام و منحنی توزیع ویژگی‌های پیوسته پس از پاک‌سازی اولیه.

۵.۳. تحلیل داده‌های پرت


برای بررسی داده‌های پرت از نمودارهای جعبه‌ای استفاده شد. شکل ۲ نشان می‌دهد ستون‌های مبلغ صورت‌حساب و به‌ویژه مبلغ پرداخت، دارای تعداد زیادی مقدار دورافتاده هستند. این مشاهده یکی از دلایل اصلی بررسی روش‌های مقاوم‌سازی در فاز پیش‌پردازش بود.




شکل ۲: نمودار جعبه‌ای ویژگی‌های پیوسته برای شناسایی داده‌های پرت.

۶.۳. تحلیل متغیرهای جمعیت‌شناختی

بررسی فراوانی متغیرهای دسته‌ای نشان داد زنان سهم بیشتری از نمونه‌ها را تشکیل می‌دهند و بخش عمده مشتریان در سطوح تحصیلی دانشگاهی قرار دارند. شکل ۳ توزیع کلی این ویژگی‌ها و شکل ۴ ارتباط آن‌ها را با متغیر هدف نشان می‌دهد. اختلاف نرخ نکول میان گروه‌های جمعیت‌شناختی وجود دارد، اما در مقایسه با سابقه پرداخت و متغیرهای مالی، این اختلاف‌ها محدودتر هستند.




شکل ۳: توزیع فراوانی ویژگی‌های دسته‌ای.



شکل ۴: توزیع متغیرهای جمعیت‌شناختی به تفکیک وضعیت نکول.

۷.۳. عدم تعادل کلاس هدف


مطابق شکل ۵، نسبت کلاس‌های متغیر هدف نامتوازن است و نسبت نمونه‌های غیرنکول به نکول حدود 3.52 برابر گزارش شد. در چنین مسئله‌ای، Accuracy به تنهایی معیار مناسبی برای ارزیابی نیست؛ زیرا مدلی که بیشتر نمونه‌ها را در کلاس اکثریت قرار دهد می‌تواند دقت ظاهراً قابل قبول ولی توان ضعیفی در کشف مشتریان پرریسک داشته باشد. به همین دلیل در ادامه، Recall، F1، ROC-AUC و به‌ویژه PR-AUC نیز در ارزیابی مدل‌ها استفاده شدند.



شکل ۵: توزیع متغیر هدف و نسبت عدم تعادل کلاس‌ها.


۸.۳. تحلیل همبستگی و الگوهای مالی

ماتریس همبستگی پیرسون در شکل ۶ نشان می‌دهد مبالغ صورت‌حساب ماه‌های مختلف همبستگی زیادی با یکدیگر دارند. این موضوع بیانگر تداوم سطح بدهی مشتری در طول ماه‌های متوالی است و هم‌زمان احتمال وجود اطلاعات تکراری میان این ویژگی‌ها را مطرح می‌کند.




شکل ۶: ماتریس همبستگی ویژگی‌های عددی.

در تحلیل همبستگی با متغیر هدف، LIMIT_BAL دارای همبستگی منفی با نکول بود. شکل ۷ نیز نشان می‌دهد توزیع سقف اعتبار در دو کلاس تفاوت دارد و مشتریان نکول‌کننده بیشتر در ناحیه اعتبارهای پایین‌تر متمرکز هستند.



شکل ۷: توزیع سقف اعتبار به تفکیک وضعیت نکول.


همچنین وضعیت بازپرداخت در ماه‌های اخیر ارتباط بیشتری با نکول نشان داد. در میان ویژگی‌های مالی پیوسته، LIMIT_BAL با ضریب حدود -0.1539 بیشترین قدر مطلق همبستگی پوینت‌بیسریال را با هدف داشت. در کنار آن، بررسی متغیرهای PAY نشان داد تأخیر پرداخت در ماه‌های نزدیک‌تر به زمان پیش‌بینی، سیگنال مهم‌تری از ریسک نکول ایجاد می‌کند.




شکل ۸: تحلیل ارتباط ویژگی‌های مالی با متغیر هدف.

همان‌طور که در شکل ۸ دیده می‌شود، وضعیت‌های تأخیر در پرداخت نسبت به بسیاری از متغیرهای مالی پیوسته ارتباط آشکارتری با وقوع نکول دارند.

از منظر زمانی نیز میانگین صورت‌حساب‌ها به‌طور محسوسی بالاتر از میانگین مبالغ پرداختی باقی می‌ماند. شکل ۹ این فاصله را در شش ماه نشان می‌دهد. این الگو بیانگر آن است که بخشی از مشتریان بدهی خود را به دوره‌های بعد منتقل می‌کنند و اطلاعات روندی می‌تواند برای ساخت ویژگی‌های جدید مفید باشد.



(ب) روند صورت حساب و پرداخت



(آ) همبستگی میالغ صورت حساب

شکل ۹: همبستگی زمانی و روند شش ماهه متغیرهای مالی.

۹.۳. پیش پردازش و مهندسی ویژگی

پس از شناخت داده، تصمیم‌های پیش‌پردازشی به صورت آزمایشی و مقایسه‌ای بررسی شدند. هدف این بود که هر انتخاب با شواهد کمی پشتیبانی شود و صرفاً بر اساس یک قاعده عمومی انجام نشود. برای قابل مقایسه بودن روش‌ها، در این فاز یک رگرسیون لجستیک به عنوان مدل مرجع و اعتبارسنجی متقابل طبقه‌بندی شده 5-fold استفاده شد. معیارهای گزارش شده شامل ROC-AUC، PR-AUC، F1 و Recall هستند. این طراحی امکان می‌دهد اثر هر تغییر در داده، تا حد امکان جدا از تغییر نوع الگوریتم سنجیده شود.

۱.۹.۳. مقایسه روش‌های برخورد با مقادیر گم‌شده

از آنجا که داده اصلی فاقد مقدار گم‌شده بود، در نوت‌بوک به صورت کنترل‌شده حدود 5% مقدار گم‌شده با سازوکار MCAR ایجاد شد تا رفتار روش‌های مختلف قابل مقایسه باشد. چهار راهبرد حذف کامل ردیف، جای‌گذاری میانگین، میانه و KNN Imputation مقایسه شدند. نتایج در جدول ۵ آمده است.

جدول ۵: مقایسه روش‌های جای‌گذاری مقادیر گمشده.

روش	ROC-AUC	PR-AUC	F1	Recall
حذف ردیف	0.7650	0.5370	0.4695	0.3601
میانگین	0.7670	0.5420	0.4677	0.3567
میانه	0.7665	0.5418	0.4668	0.3555
KNN با $k = 5$	0.7676	0.5419	0.4676	0.3564

بر مبنای معیار انتخاب استفاده‌شده در این مرحله، KNN Imputation با ROC-AUC=0.7676 بالاترین مقدار را به دست آورد و به عنوان راهبرد برتر ثبت شد. با این حال، اختلاف آن با جای‌گذاری میانگین و میانه بسیار کوچک است و PR-AUC سه روش تقریباً در محدوده 0.542 قرار دارد. بنابراین نتیجه اصلی این آزمایش برتری قاطع یک روش جای‌گذاری نیست، بلکه نشان می‌دهد حذف سطرها اطلاعات مفید را از بین می‌برد و عملکرد ضعیف‌تری ایجاد می‌کند. از آنجا که داده اصلی مقدار گمشده واقعی ندارد، این آزمایش بیشتر به عنوان یک آزمون پایداری Robustness Test برای سنجش رفتار خط لوله در حضور فقدان مصنوعی داده تفسیر می‌شود و در نتایج نهایی، جای‌گذاری نقش عملی محدودی دارد.

۲.۹.۳. مقایسه روش‌های مقیاس‌بندی

سه روش StandardScaler، MinMaxScaler و RobustScaler مقایسه شدند. ضرورت این مقایسه از اختلاف شدید مقیاس متغیرها ناشی می‌شود؛ برای مثال، سن در مقیاس ده‌ها واحد قرار دارد، در حالی که سقف اعتبار و صورت‌حساب‌ها می‌توانند به صدها هزار واحد برسند. طبق جدول ۶، StandardScaler و RobustScaler از نظر ROC-AUC تقریباً برابر بودند، اما StandardScaler با PR-AUC=0.5421 اندکی بالاتر قرار گرفت. MinMaxScaler در هر دو معیار اصلی کمی ضعیف‌تر بود. کوچک بودن اختلاف‌ها نشان می‌دهد نتیجه مدل مرجع نسبت به نوع مقیاس‌بندی حساسیت شدیدی ندارد، با این حال StandardScaler به عنوان انتخاب نهایی ثبت شد.

جدول ۶: مقایسه روش‌های مقیاس‌بندی.

روش	ROC-AUC	PR-AUC	F1	Recall
StandardScaler	0.7679	0.5421	0.4673	0.3561
MinMaxScaler	0.7651	0.5400	0.4659	0.3546
RobustScaler	0.7679	0.5420	0.4668	0.3555

۳.۹.۳. مهندسی و انتخاب ویژگی

بر اساس شناخت حاصل از تحلیل اکتشافی، چهار ویژگی جدید ساخته شدند. متوسط مبلغ صورت حساب و متوسط مبلغ پرداخت، رفتار کلی مشتری را طی شش ماه خلاصه می کنند و به ترتیب مطابق روابط ۱ و ۲ تعریف شدند:

$$AVG_BILL_AMT = \frac{1}{6} \sum_{i=1}^6 BILL_AMT_i \quad (۱)$$

$$AVG_PAY_AMT = \frac{1}{6} \sum_{i=1}^6 PAY_AMT_i \quad (۲)$$

سپس نسبت پرداخت به صورت حساب و نرخ استفاده از سقف اعتبار به صورت روابط ۳ و ۴ تعریف شدند:

$$PAY_TO_BILL_RATIO = \frac{AVG_PAY_AMT}{|AVG_BILL_AMT| + 1} \quad (۳)$$

$$CREDIT_UTILIZATION = \frac{BILL_AMT1}{|LIMIT_BAL| + 1} \quad (۴)$$

سه حالت بدون مهندسی ویژگی، با مهندسی ویژگی، با مهندسی ویژگی همراه با انتخاب ویژگی L1 بررسی شدند. نتایج جدول ۷ نشان داد دو حالت دارای مهندسی ویژگی ROC-AUC=0.7683 به دست آوردند که تنها 0.0004 بیشتر از خط پایه است. در مقابل، PR-AUC از 0.5420 به 0.5410 کاهش جزئی داشت. بنابراین، مهندسی ویژگی در مدل خطی مرجع جهش بزرگی در عملکرد ایجاد نکرد. با این حال، ویژگی های ساخته شده اطلاعات رفتاری قابل تفسیرتری از شش ماه گذشته ایجاد می کنند و بعداً CREDIT_UTILIZATION و PAY_TO_BILL_RATIO در تحلیل SHAP نیز در میان ویژگی های مهم ظاهر شدند. به همین دلیل حالت «مهندسی ویژگی بدون حذف ویژگی ها» حفظ شد تا مدل های غیرخطی نیز بتوانند از برهم کنش این شاخص ها استفاده کنند.

جدول ۷: نتایج مهندسی و انتخاب ویژگی.

Recall	F1	PR-AUC	ROC-AUC	روش
0.3555	0.4668	0.5420	0.7679	بدون مهندسی ویژگی
0.3557	0.4666	0.5410	0.7683	با مهندسی ویژگی
0.3557	0.4667	0.5410	0.7683	مهندسی ویژگی + انتخاب L1

۴.۹.۳. مدیریت داده‌های پرت

دو حالت حفظ داده‌های پرت و محدودسازی مبتنی بر IQR با ضریب 1.5 مقایسه شدند. هدف از محدودسازی، حذف مشتریان با تراکنش‌های بزرگ نبود؛ بلکه کاهش اثر مقادیر بسیار دورافتاده بر پارامترهای مدل مرجع بود. نتیجه جدول ۸ نشان داد محدودسازی باعث افزایش ROC-AUC از 0.7679 به 0.7706 و PR-AUC از 0.5420 به 0.5460 شد. در عین حال، F1 و Recall در آستانه پیش‌فرض اندکی کاهش یافتند. این تفاوت نشان می‌دهد محدودسازی قدرت رتبه‌بندی کلی مدل را بهتر کرده است، اما مرز تصمیم ثابت 0.5 الزاماً همان میزان بهبود را در پیش‌بینی دودویی نشان نمی‌دهد. با توجه به معیارهای رتبه‌بندی، محدودسازی IQR به عنوان گزینه برتر ثبت شد.

جدول ۸: مقایسه روش‌های مدیریت داده‌های پرت.

روش	ROC-AUC	PR-AUC	F1	Recall
حفظ داده‌های پرت	0.7679	0.5420	0.4668	0.3555
محدودسازی IQR	0.7706	0.5460	0.4628	0.3511

۵.۹.۳. مدیریت عدم تعادل کلاس‌ها

چهار رویکرد بدون مداخله، وزن‌دهی متوازن به کلاس‌ها، SMOTE و نمونه‌برداری کاهشی تصادفی بررسی شدند. همان‌طور که جدول ۹ نشان می‌دهد، روش بدون مداخله بیشترین PR-AUC=0.5420 را ثبت کرد؛ اما Recall آن تنها 0.3555 بود. در مقابل، وزن‌دهی متوازن، SMOTE و نمونه‌برداری کاهشی، فراخوانی را به ترتیب به 0.5774، 0.5805 و 0.5751 افزایش دادند. بنابراین مدیریت عدم تعادل یک مصالحه روشن میان «کشف تعداد بیشتری از نکول‌کنندگان» و «حفظ کیفیت کلی رتبه‌بندی Precision-Recall» ایجاد می‌کند.

از دید مدیریت ریسک، افزایش Recall می‌تواند مطلوب باشد، زیرا کاهش FN به معنی از دست ندادن مشتریان پرریسک است؛ اما این افزایش معمولاً با افزایش هشدارهای کاذب و افت Precision همراه می‌شود. به همین دلیل در این پروژه هیچ روش متوازن‌سازی صرفاً به دلیل افزایش Recall برنده اعلام نشد و مقایسه بر اساس مجموعه‌ای از معیارها انجام شد.

جدول ۹: مقایسه روش‌های مدیریت عدم تعادل کلاس.

روش	ROC-AUC	PR-AUC	F1	Recall
بدون مداخله	0.7679	0.5420	0.4668	0.3555
class_weight=balanced	0.7681	0.5399	0.5321	0.5774
SMOTE	0.7671	0.5386	0.5280	0.5805
RandomUnderSampler	0.7670	0.5378	0.5296	0.5751

۶.۹.۳. پیکربندی منتخب فاز پیش‌پردازش

خروجی نهایی فاز دوم نوت‌بوک، پیکربندی جدول ۱۰ را به عنوان مجموعه تصمیم‌های منتخب ثبت کرد. این جدول علاوه بر روش انتخاب‌شده، منطق اصلی تصمیم را نیز خلاصه می‌کند.

جدول ۱۰: خلاصه تصمیم‌های منتخب در فاز پیش‌پردازش.

مرحله	انتخاب ثبت‌شده	منطق اصلی انتخاب
مقادیر گم‌شده	KNN Imputation (k=5)	بیشترین ROC-AUC در آزمایش MCAR؛ با توجه به نبود مقدار گم‌شده واقعی، این نتیجه بیشتر نقش آزمون پایداری دارد.
مقیاس‌بندی	StandardScaler	عملکرد بسیار نزدیک به RobustScaler و اندکی PR-AUC بالاتر.
مهندسی ویژگی	چهار ویژگی جدید	بهبود جزئی ROC-AUC و فراهم کردن شاخص‌های قابل تفسیر از رفتار شش‌ماهه.
داده‌های پرت	محدودسازی مبتنی بر IQR	افزایش هم‌زمان ROC-AUC و PR-AUC در آزمایش مقایسه‌ای.
عدم تعادل	بدون نمونه‌برداری به عنوان خط پایه برنده	بیشترین PR-AUC؛ در عین حال، افزایش Recall در روش‌های وزن‌دهی و نمونه‌برداری به عنوان یک مصالحه مهم ثبت شد.

۷.۹.۳. تقسیم داده برای مدل‌سازی

پس از تکمیل مراحل آماده‌سازی، داده با روش Stratified Train-Test Split و نسبت 80:20 به مجموعه آموزش و آزمون تقسیم شد تا نسبت کلاس نکول در هر دو بخش حفظ شود. در نتیجه، مجموعه آموزش شامل 23,972 نمونه و مجموعه آزمون شامل 5,993 نمونه بود و نرخ نکول در هر دو مجموعه تقریباً 0.2213 باقی ماند. این تقسیم‌بندی مبنای آموزش و ارزیابی نهایی مدل‌ها در بخش بعد است.

۴. مدل و نتایج

پس از شناخت ساختار داده و تعیین روش‌های پیش‌پردازش، در این بخش مدل‌های مختلف برای پیش‌بینی نکول مشتریان آموزش و ارزیابی شدند. هدف از این مرحله صرفاً دستیابی به بیشترین مقدار صحت نبود؛ بلکه تلاش شد مدلی انتخاب شود که با توجه به نامتوازن بودن متغیر هدف، توانایی مناسبی در شناسایی مشتریان نکول‌کننده داشته باشد و در عین حال، عملکرد آن بر اساس چند معیار مختلف قابل دفاع باشد.

برای جلوگیری از وابستگی نتیجه به یک خانواده خاص از الگوریتم‌ها، پنج مدل با ساختارهای متفاوت بررسی شدند: درخت تصمیم، جنگل تصادفی، XGBoost، LightGBM و رگرسیون لجستیک. این مجموعه از یک مدل خطی ساده تا مدل‌های گروهی و تقویتی غیرخطی را پوشش می‌دهد و امکان بررسی این موضوع را فراهم می‌کند که آیا افزایش پیچیدگی مدل واقعاً موجب بهبود قابل توجه قدرت پیش‌بینی می‌شود یا خیر.

۱.۴. تنظیمات آزمایش و فرایند آموزش

پس از اتمام مراحل پیش‌پردازش، داده‌ها با حفظ نسبت کلاس هدف به دو مجموعه آموزش و آزمون تقسیم شدند. از روش تقسیم طبقه‌بندی شده Stratified Train-Test Split استفاده شد تا نسبت مشتریان نکول‌کننده و غیرنکول‌کننده در دو مجموعه تقریباً یکسان باقی بماند. نسبت داده آموزش به آزمون برابر با 80:20 در نظر گرفته شد.

در نتیجه، مجموعه آموزش شامل 23,972 نمونه و مجموعه آزمون شامل 5,993 نمونه بود. نرخ نکول در هر دو مجموعه تقریباً 0.2213 به دست آمد. ثابت بودن این نسبت نشان می‌دهد که تقسیم داده ساختار نامتوازن مسئله را میان آموزش و آزمون حفظ کرده است.

برای مقایسه منصفانه مدل‌ها، از اعتبارسنجی متقابل طبقه‌بندی شده 5-fold Stratified Cross-Validation استفاده شد. همچنین مقدار random_state=42 در مراحل تصادفی ثابت نگه داشته شد تا نتایج قابلیت تکرار بیشتری داشته باشند. تنظیم ابرپارامترها با استفاده از RandomizedSearchCV انجام شد. دلیل انتخاب جست‌وجوی تصادفی به جای بررسی همه ترکیبات ممکن آن است که فضای ابرپارامتر مدلهایی مانند Random Forest، XGBoost و LightGBM نسبتاً بزرگ است و بررسی تمام ترکیبات هزینه محاسباتی بالایی ایجاد می‌کند. در این روش، تعداد مشخصی ترکیب از فضای پارامترها انتخاب و هر ترکیب با اعتبارسنجی متقابل ارزیابی شد.

در فرایند تنظیم، معیار اصلی برای انتخاب ترکیب برتر PR-AUC در نظر گرفته شد. دلیل این انتخاب، نامتوازن بودن متغیر هدف است؛ زیرا در چنین مسئله‌ای کیفیت تشخیص کلاس اقلیت اهمیت بیشتری از درصد کلی پیش‌بینی‌های صحیح دارد.

۲.۴. معیارهای ارزیابی

با توجه به اینکه تنها حدود 22.1% نمونه‌ها متعلق به مشتریان نکول‌کننده هستند، اتکا به Accuracy به تنهایی می‌تواند گمراه‌کننده باشد. از این رو، شش معیار Precision، Recall، F1-Score، ROC-AUC و PR-AUC برای ارزیابی مدل‌ها مورد استفاده قرار گرفتند.

در روابط زیر، TP تعداد نکول‌کنندگان درست شناسایی شده، TN تعداد غیرنکول‌کنندگان درست شناسایی شده، FP تعداد هشدارهای کاذب و FN تعداد نکول‌کنندگان از دست رفته را نشان می‌دهد.

صحت یا Accuracy نسبت کل پیش‌بینی‌های صحیح به تمام نمونه‌هاست و مطابق رابطه ۵ محاسبه می‌شود:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

معيار Precision نشان می‌دهد چه نسبتی از مشتریانی که مدل پریسک تشخیص داده است، واقعاً نکول کرده‌اند و از رابطه ۶ به دست می‌آید:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (6)$$

معيار Recall بیانگر درصد مشتریان نکول‌کننده واقعی است که مدل موفق به شناسایی آن‌ها شده است و از رابطه ۷ محاسبه می‌شود:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (7)$$

از آنجا که در مسئله حاضر عدم شناسایی یک مشتری واقعاً پریسک (False Negative) می‌تواند منجر به اعطای اعتبار به مشتری دارای ریسک نکول شود، Recall از منظر کسب‌وکار اهمیت ویژه‌ای دارد.

معيار F1-Score میانگین هارمونیک Precision و Recall است و طبق رابطه ۸ تعادل میان این دو معیار را نشان می‌دهد:

$$F_1 = 2 \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (8)$$

معيار ROC-AUC توانایی کلی مدل در رتبه‌بندی نمونه‌های مثبت و منفی را در آستانه‌های مختلف بررسی می‌کند. با این حال، در داده‌های نامتوازن ممکن است به دلیل تعداد زیاد نمونه‌های منفی، تصویر نسبتاً خوش‌بینانه‌ای از عملکرد ارائه کند. به همین دلیل، PR-AUC نیز محاسبه شد. این معیار رابطه Precision-Recall را در آستانه‌های مختلف بررسی کرده و برای تحلیل عملکرد کلاس اقلیت مناسب‌تر است. بر همین اساس، PR-AUC معیار اصلی رتبه‌بندی مدل‌های این پروژه در نظر گرفته شد.

۳.۴. انتخاب الگوریتم‌ها

مدل‌های مورد استفاده با هدف پوشش ساختارهای متفاوت تصمیم‌گیری انتخاب شدند.

درخت تصمیم. درخت تصمیم به عنوان یک مدل غیرخطی ساده و قابل تفسیر انتخاب شد. این مدل قادر است روابط غیرخطی و برهم‌کنش بین ویژگی‌ها را بدون فرض رابطه خطی استخراج کند. در عین حال، درخت تصمیم عمیق مستعد بیش‌برازش است؛ بنابراین پارامترهایی مانند max_depth، min_samples_split و min_samples_leaf در فرایند تنظیم مورد توجه قرار گرفتند.

جنگل تصادفی. جنگل تصادفی با تجمیع تعداد زیادی درخت تصمیم و استفاده از نمونه‌گیری بوت‌استرپ، واریانس بالای یک درخت منفرد را کاهش می‌دهد [۱۱]. این مدل به دلیل مقاومت نسبی در برابر نویز و توانایی مدل‌سازی روابط غیرخطی برای داده‌های مالی گزینه مناسبی محسوب می‌شود.

XGBoost. مدل XGBoost بر پایه تقویت گرادیانی ساخته شده است و درخت‌ها به صورت متوالی آموزش داده می‌شوند [۱۲]؛ به‌گونه‌ای که هر مرحله تلاش می‌کند خطاهای مراحل قبلی را کاهش دهد. وجود منظم‌سازی، کنترل عمق درخت‌ها، نمونه‌گیری سطری و ستونی و پارامتر `scale_pos_weight` باعث می‌شود این الگوریتم برای داده‌های جدولی و مسائل نامتوازن گزینه‌ای قدرتمند باشد.

LightGBM. مدل LightGBM نیز از خانواده روش‌های تقویت گرادیانی است، اما رشد درخت در آن به صورت `leaf-wise` انجام می‌شود [۱۳]. این ساختار می‌تواند با تعداد گره کمتر روابط پیچیده را استخراج کند و سرعت آموزش بالایی دارد. پارامتر `is_unbalance=True` نیز در این مدل برای توجه بیشتر به کلاس اقلیت استفاده شد.

رگرسیون لجستیک. رگرسیون لجستیک به عنوان خط مبنای خطی `Linear Benchmark` در نظر گرفته شد. هدف از حضور این مدل آن بود که مشخص شود مدل‌های پیچیده‌تر تا چه اندازه نسبت به یک مدل ساده و قابل تفسیر برتری دارند. اگر مدل‌های غیرخطی تنها بهبود بسیار محدودی ایجاد می‌کردند، پیچیدگی بیشتر آن‌ها از منظر کاربرد عملی الزاماً توجیه‌پذیر نبود.

۴.۴. تنظیم ابرپارامترها

برای هر یک از پنج مدل، ابتدا یک نسخه پایه آموزش داده شد و سپس فرایند تنظیم ابرپارامترها با `RandomizedSearchCV` و اعتبارسنجی متقابل `5-fold` انجام گرفت. تعداد ترکیبات آزمایش شده برای درخت تصمیم، جنگل تصادفی، XGBoost، LightGBM و رگرسیون لجستیک به ترتیب 20، 30، 40، 30 و 20 ترکیب بود. در تمام جست‌وجوها، مدل نهایی هر ترکیب بر اساس `PR-AUC` اعتبارسنجی انتخاب شد و سپس بهترین تخمین‌گر روی کل مجموعه آموزش برآزش مجدد شد. فضای جست‌وجو به گونه‌ای طراحی شد که هم مدل‌های کم‌ظرفیت و هم مدل‌های پیچیده‌تر را پوشش دهد و امکان مشاهده مصالحه بایاس و واریانس فراهم شود. خلاصه منطق انتخاب بازه‌ها در جدول ۱۱ آمده است.

جدول ۱۱: فضای جست‌وجوی ابرپارامترها و منطق انتخاب مقادیر.

مدل	ابرپارامتر	فضای جست‌وجو	منطق انتخاب
درخت تصمیم	max_depth	{4,6,8,10,12,15,20,None}	بررسی ساختارهایی از درخت نسبتاً کم‌عمق تا درخت بدون محدودیت؛ هدف، کنترل مصالحه میان بیش‌برازش و کم‌برازش بود.
	min_samples_split	{2,10,20,50,100}	افزایش حداقل نمونه لازم برای تقسیم یک گره، از ایجاد شاخه‌های بسیار جزئی و حساس به نویز جلوگیری می‌کند.
	min_samples_leaf	{1,5,10,20,50}	این پارامتر حداقل تعداد مشاهدات هر برگ را کنترل کرده و به عنوان نوعی هرس پیش از رشد کامل درخت عمل می‌کند.
جنگل تصادفی	n_estimators	200–700	افزایش تعداد درخت‌ها موجب کاهش واریانس برآورد می‌شود، اما پس از تعداد مشخصی، بهبود عملکرد نسبت به هزینه محاسباتی محدود می‌شود.
	max_depth	{None,8,12,16,24}	برای مقایسه درخت‌های بدون محدودیت با ساختارهای کنترل‌شده‌تر و کاهش احتمال بیش‌برازش بررسی شد.
	max_features	{sqrt,log2,0.5}	محدود کردن تعداد ویژگی‌های قابل بررسی در هر تقسیم، همبستگی میان درخت‌ها را کاهش داده و تنوع مجموعه را افزایش می‌دهد.
XGBoost	n_estimators	100–600	تعداد مراحل تقویت را کنترل می‌کند؛ تعداد بیشتر درخت‌ها می‌تواند ظرفیت مدل را افزایش دهد، به‌ویژه در کنار نرخ یادگیری کوچک.
	learning_rate	0.01–0.20	نرخ‌های کوچک‌تر موجب یادگیری تدریجی‌تر شده و معمولاً خطر بیش‌برازش را کاهش می‌دهند، اما به تعداد درخت بیشتری نیاز دارند.
	max_depth	3–8	برای کنترل پیچیدگی یادگیرنده‌های پایه و جلوگیری از ایجاد درخت‌های بیش از حد پیچیده بررسی شد.
	subsample	0.6–1.0	استفاده از بخشی از نمونه‌ها در هر مرحله باعث کاهش واریانس و افزایش مقاومت مدل در برابر بیش‌برازش می‌شود.
	colsample_bytree	0.5–1.0	با انتخاب تصادفی زیرمجموعه‌ای از ویژگی‌ها برای هر درخت، وابستگی درخت‌ها کاهش یافته و تعمیم مدل بهبود می‌یابد.
LightGBM	n_estimators	100–500	برای بررسی تعداد مختلف مراحل تقویت و یافتن تعادل بین ظرفیت مدل و هزینه محاسباتی انتخاب شد.
	learning_rate	0.01–0.15	نرخ‌های کوچک‌تر امکان یادگیری تدریجی و پایدارتر را فراهم می‌کنند و در کنار تعداد بیشتر درخت‌ها بررسی شدند.
	num_leaves	{15,31,63,127}	در ساختار leaf-wise این پارامتر یکی از مهم‌ترین کنترل‌کننده‌های ظرفیت مدل است و تعداد بیشتر برگ‌ها می‌تواند روابط پیچیده‌تری را مدل کند.
	min_child_samples	{20,50,100,200}	افزایش تعداد حداقل نمونه‌های هر برگ، رشد شاخه‌های بسیار خاص را محدود کرده و نقش منظم‌سازی دارد.
رگرسیون لجستیک	C	0.001–50	برای بررسی شدت‌های مختلف منظم‌سازی، از منظم‌سازی بسیار قوی تا ضعیف، بازه‌ای چندمرتبه‌ای در نظر گرفته شد.
	penalty	{L1,L2} ۲۹	L1 امکان ایجاد ضرایب تنک و حذف عملی برخی ویژگی‌ها را فراهم می‌کند، در حالی که L2 ضرایب را به صورت نرم‌تر کوچک می‌کند.
	solver	{liblinear,saga}	این دو حل‌گر با انواع منظم‌سازی مورد استفاده سازگار هستند و امکان مقایسه رفتار الگوریتم در فرایند

بهترین مقدار CV PR-AUC برای درخت تصمیم، جنگل تصادفی، XGBoost، LightGBM و رگرسیون لجستیک به ترتیب 0.5132، 0.5617، 0.5647، 0.5647 و 0.5423 به دست آمد. این نتایج نشان می‌دهد پیش از مشاهده مجموعه آزمون نیز مدل‌های گروهی و تقویتی در اعتبارسنجی متقابل نسبت به درخت منفرد و مدل خطی عملکرد قوی‌تری داشته‌اند. بهترین ابرپارامترهای به‌دست‌آمده در جدول ۱۲ ارائه شده‌اند.

جدول ۱۲: بهترین ابرپارامترهای مدل‌ها بر اساس RandomizedSearchCV.

مدل	اب‌پارامتر	مقدار بهینه
درخت تصمیم	max_depth	6
	min_samples_split	100
	min_samples_leaf	1
	criterion	entropy
	max_features	None
	class_weight	balanced
جنگل تصادفی	n_estimators	700
	max_depth	8
	min_samples_split	10
	min_samples_leaf	8
	max_features	0.5
	criterion	gini
	class_weight	balanced
XGBoost	n_estimators	600
	learning_rate	0.01
	max_depth	6
	min_child_weight	5
	subsample	0.6
	colsample_bytree	0.6
	gamma	0.1
	reg_alpha	1.0
	reg_lambda	5.0
	scale_pos_weight	3.52
LightGBM	n_estimators	400
	learning_rate	0.01
	num_leaves	15
	min_child_samples	50
	feature_fraction	0.7
	bagging_fraction	0.9
	bagging_freq	10
	reg_alpha	0
	reg_lambda	0.01
	is_unbalance	True

در XGBoost مقدار $\text{scale_pos_weight}=3.52$ بر اساس نسبت تعداد نمونه‌های کلاس غیرنکول به نکول تعیین شد. در مجموعه آموزش تعداد نمونه‌های دو کلاس تقریباً 18,668 و 5,304 بود که نسبت آن‌ها حدود 3.52 است. این وزن باعث می‌شود خطا روی مشتریان نکول‌کننده در فرایند آموزش تأثیر بیشتری داشته باشد.


۵.۴. اثر تنظیم ابرپارامترها

برای بررسی واقعی اثر تنظیم ابرپارامترها، عملکرد نسخه پایه و نسخه تنظیم‌شده هر مدل روی مجموعه آزمون مقایسه شد. نتایج کامل در جدول ۱۳ آمده است.

جدول ۱۳: مقایسه عملکرد مدل‌های پایه و تنظیم‌شده روی مجموعه آزمون.


مدل	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
درخت تصمیم پایه	0.7305	0.3904	0.3884	0.3894	0.6082	0.2873
درخت تصمیم تنظیم‌شده	0.7739	0.4903	0.5551	0.5207	0.7432	0.4950
جنگل تصادفی پایه	0.8021	0.5609	0.4864	0.5210	0.7637	0.5241
جنگل تصادفی تنظیم‌شده	0.7729	0.4889	0.5837	0.5321	0.7744	0.5548
XGBoost پایه	0.7576	0.4612	0.5694	0.5096	0.7545	0.5301
XGBoost تنظیم‌شده	0.7606	0.4691	0.6237	0.5354	0.7810	0.5634
LightGBM پایه	0.7587	0.4658	0.6154	0.5302	0.7728	0.5556
LightGBM تنظیم‌شده	0.7530	0.4576	0.6259	0.5287	0.7799	0.5537
رگرسیون لجستیک پایه	0.7741	0.4909	0.5724	0.5286	0.7641	0.5360
رگرسیون لجستیک تنظیم‌شده	0.7742	0.4913	0.5732	0.5291	0.7640	0.5346

نتایج جدول نشان می‌دهد تنظیم ابرپارامترها در همه مدل‌ها اثر یکسانی نداشته است. بیشترین تغییر در درخت تصمیم مشاهده شد. مقدار PR-AUC این مدل از 0.2873 به 0.4950 و مقدار Recall از 0.3884 به 0.5551 افزایش یافت. این تغییر نشان می‌دهد درخت پایه به شدت به انتخاب ساختار درخت حساس بوده و محدود کردن عمق و کنترل تقسیم گره‌ها از بیش‌برازش جلوگیری کرده است. شکل ۱۰ نیز نشان می‌دهد پس از تنظیم، منحنی‌های ROC و Precision-Recall نسبت به مدل پایه بهبود محسوس‌تری داشته‌اند.




شکل ۱۰: ماتریس درهم‌ریختگی و منحنی‌های تشخیصی درخت تصمیم پس از تنظیم ابرپارامترها.

در جنگل تصادفی، تنظیم مدل باعث کاهش Accuracy از 0.8021 به 0.7729 شد؛ اما هم‌زمان Recall از 0.4864 به 0.5837 و PR-AUC از 0.5241 به 0.5548 افزایش یافت. بنابراین کاهش صحت کلی در اینجا الزاماً به معنای ضعیف‌تر شدن مدل نیست. مدل تنظیم‌شده بخشی از عملکرد خود روی کلاس اکثریت را فدای شناسایی تعداد بیشتری از مشتریان نکول‌کننده کرده است؛ رفتاری که با هدف مسئله ریسک اعتباری سازگارتر است. در شکل ۱۱ نیز این جابه‌جایی در مصالحه میان هشدارهای بیشتر و شناسایی کلاس اقلیت قابل مشاهده است.



شکل ۱۱: ماتریس درهم‌ریختگی و منحنی‌های ROC و Precision-Recall جنگل تصادفی.


در XGBoost اثر تنظیم ابرپارامترها واضح و در چند معیار هم‌زمان مثبت بود. مقدار PR-AUC از 0.5301 به 0.5634، ROC-AUC از 0.7545 به 0.7810 و Recall از 0.5694 به 0.6237 افزایش یافت. همچنین F1 از 0.5096 به 0.5354 رسید. این الگو نشان می‌دهد تنظیم مدل صرفاً یک معیار را بهبود نداده، بلکه توانایی رتبه‌بندی و شناسایی کلاس نکول را به صورت هم‌زمان تقویت کرده است. شکل ۱۲ سه نمای مکمل از عملکرد مدل نهایی ارائه می‌کند: ماتریس درهم‌ریختگی، منحنی ROC و منحنی Precision-Recall. فاصله منحنی تنظیم‌شده از مدل پایه در دو نمودار آخر، بهبود کمی ثبت‌شده در جدول را تأیید می‌کند.



شکل ۱۲: ماتریس درهم‌ریختگی و منحنی‌های ROC و Precision-Recall مدل XGBoost.


در LightGBM وضعیت متفاوت بود. تنظیم ابرپارامترها باعث افزایش ROC-AUC از 0.7728 به 0.7799 و Recall از 0.6154 به 0.6259 شد؛ با این حال، PR-AUC اندکی از 0.5556 به 0.5537 کاهش یافت و F1 نیز از 0.5302 به 0.5287 رسید. این نتیجه نشان می‌دهد تنظیم ابرپارامتر لزوماً تمام معیارهای آزمون را بهبود نمی‌دهد و انتخاب مدل باید بر

اساس مجموعه‌ای از معیارها انجام شود. شکل ۱۳ نیز نشان می‌دهد بهبود رتبه‌بندی در منحنی ROC الزاماً با بهبود هم‌زمان ناحیه Precision-Recall همراه نیست.



شکل ۱۳: ماتریس درهم‌ریختگی و منحنی‌های تشخیصی مدل LightGBM.

برای رگرسیون لجستیک نیز تفاوت نسخه پایه و تنظیم‌شده بسیار محدود بود. مقدار Accuracy تقریباً بدون تغییر باقی ماند و PR-AUC حتی اندکی از 0.5360 به 0.5346 کاهش یافت. این نتیجه نشان می‌دهد بخش عمده ظرفیت مدل خطی با تنظیم پایه بالفعل شده و تغییر پارامترهای منظم‌سازی اثر محدودی بر ساختار پیش‌بینی داشته است. شکل ۱۴ نیز نزدیکی منحنی‌های مدل پایه و تنظیم‌شده را نشان می‌دهد.



شکل ۱۴: ماتریس درهم‌ریختگی و منحنی‌های تشخیصی رگرسیون لجستیک.

۶.۴. مقایسه نهایی مدل‌ها


برای انتخاب مدل نهایی، عملکرد نسخه‌های تنظیم‌شده پنج الگوریتم بر روی مجموعه آزمون در جدول ۱۴ مقایسه شد.

جدول ۱۴: مقایسه نهایی مدل‌های تنظیم‌شده روی مجموعه آزمون.

PR-AUC	ROC-AUC	F1	Recall	Precision	Accuracy	مدل
0.4950	0.7432	0.5207	0.5551	0.4903	0.7739	درخت تصمیم
0.5548	0.7744	0.5321	0.5837	0.4889	0.7729	جنگل تصادفی
0.5634	0.7810	0.5354	0.6237	0.4691	0.7606	XGBoost
0.5537	0.7799	0.5287	0.6259	0.4576	0.7530	LightGBM
0.5346	0.7640	0.5291	0.5732	0.4913	0.7742	رگرسیون لجستیک

جدول فوق یکی از نکات مهم این پروژه را نشان می‌دهد: مدلی که بیشترین Accuracy را دارد، الزاماً بهترین مدل برای مسئله نکول نیست. رگرسیون لجستیک با مقدار 0.7742 بیشترین صحت را در میان نسخه‌های تنظیم‌شده دارد، در حالی که XGBoost با صحت کمتر 0.7606 از نظر PR-AUC، ROC-AUC، Recall و F1 عملکرد رقابتی‌تر و متوازن‌تری ارائه می‌دهد.

بیشترین Recall متعلق به LightGBM و برابر با 0.6259 است، اما اختلاف آن با XGBoost که مقدار 0.6237 را به دست آورده، تنها حدود 0.0022 است. در مقابل، XGBoost دارای بالاترین PR-AUC برابر با 0.5634 و بالاترین ROC-AUC برابر با 0.7810 است. همچنین مقدار $F1=0.5354$ این مدل از تمام مدل‌های دیگر بیشتر است. از این رو، XGBoost به عنوان مدل نهایی انتخاب شد. دلیل انتخاب آن صرفاً بیشترین مقدار یک شاخص نبود؛ بلکه این مدل بهترین PR-AUC را در کنار ROC-AUC بالا، فراخوانی مناسب و بیشترین F1 ارائه کرد. با توجه به نامتوازن بودن کلاس‌ها، این ترکیب نسبت به تکیه صرف بر Accuracy برای مسئله حاضر مناسب‌تر ارزیابی شد. برای ارائه یک نمای یکپارچه از اختلاف مدل‌ها، شکل ۱۵ مقادیر معیارهای اصلی را در کنار یکدیگر نشان می‌دهد. این نمودار به‌ویژه نشان می‌دهد که برتری مدل‌ها به معیار انتخابی وابسته است: رگرسیون لجستیک در Accuracy اندکی بهتر است، LightGBM بالاترین Recall را دارد و XGBoost در سه معیار PR-AUC، ROC-AUC و F1 برتری دارد.



شکل ۱۵: مقایسه جامع عملکرد مدل‌های تنظیم‌شده روی مجموعه آزمون.

۷.۴. تحلیل ماتریس درهم‌ریختگی مدل نهایی

برای بررسی دقیق‌تر عملکرد XGBoost، پیش‌بینی‌های مجموعه آزمون به چهار گروه TP، TN، FP و FN تقسیم شدند. نتایج در جدول ۱۵ ارائه شده‌اند.

جدول ۱۵: تعداد نمونه‌های چهار گروه حاصل از ماتریس درهم‌ریختگی مدل XGBoost.

گروه	تعداد	درصد از مجموعه آزمون
TP	827	13.8%
TN	3,731	62.3%
FP	936	15.6%
FN	499	8.3%

بنابراین، مدل از مجموع 1,326 مشتری واقعاً نکول‌کننده، 827 نفر را به درستی شناسایی کرده و 499 نفر را به اشتباه در گروه کم‌ریسک قرار داده است. این مقدار دقیقاً با $Recall=0.6237$ سازگار است. در مقابل، از میان مشتریان غیرنکول‌کننده، 3,731 نفر به درستی کم‌ریسک تشخیص داده شده‌اند و 936 نفر به اشتباه در گروه پرریسک قرار گرفته‌اند.


از منظر کسب‌وکار، دو نوع خطا پیامد یکسانی ندارند. FP به معنای مشتری خوش‌حسابی است که مدل او را پرریسک تشخیص داده است. این خطا ممکن است موجب رد یا محدود شدن اعتبار یک مشتری مناسب و در نتیجه ایجاد هزینه فرصت و کاهش رضایت مشتری شود.

در مقابل، FN مشتری‌ای است که واقعاً نکول کرده اما مدل او را کم‌ریسک تشخیص داده است. این نوع خطا از منظر ریسک اعتباری اهمیت بیشتری دارد؛ زیرا می‌تواند مستقیماً به تخصیص اعتبار به یک مشتری پرریسک منجر شود. به همین دلیل، صرف گزارش تعداد خطاها کافی نیست و لازم است بررسی شود چه الگوهایی باعث ایجاد FP و FN شده‌اند.

۸.۴. تحلیل توزیعی خطاهای مدل

برای یافتن الگوهای ساختاری موجود در خطاهای مدل، پنج ویژگی PAY_AMT1، PAY_0، LIMIT_BAL، AGE و BILL_AMT1 در چهار گروه خطا بررسی شدند. دو نوع نمودار برای این تحلیل به کار رفت: نمودار چگالی KDE برای مقایسه شکل کامل توزیع‌ها و نمودار جعبه‌ای برای بررسی میانه، پراکندگی و داده‌های پرت.

KDE Density: Feature Distributions by Error Cohort



شکل ۱۶: مقایسه توزیع چگالی ویژگی‌های منتخب در چهار گروه TP، TN، FP و FN.

شکل ۱۶ نشان می‌دهد توزیع تمام ویژگی‌ها میان چهار گروه به یک اندازه متفاوت نیست. بیشترین جدایی در متغیرهای مرتبط با سابقه بازپرداخت و توان اعتباری مشاهده می‌شود، در حالی که سن هم‌پوشانی بسیار زیادی میان چهار گروه دارد. برای کمی‌سازی این تفاوت‌ها، میانگین پنج ویژگی منتخب در جدول ۱۶ ارائه شده است.

جدول ۱۶: میانگین ویژگی‌های منتخب در چهار گروه خطای مدل XGBoost

ویژگی	TP	TN	FP	FN
LIMIT_BAL	113216.44	192621.28	120801.28	164669.34
PAY_0	1.27	-0.41	0.47	-0.36
PAY_AMT1	2327.98	7433.20	1942.47	5883.01
BILL_AMT1	44313.11	56665.99	31198.24	60857.75
AGE	36.56	35.43	35.36	35.64

تحلیل سقف اعتبار. میانگین LIMIT_BAL در گروه TP حدود 113216.44 است، در حالی که این مقدار برای TN حدود 192621.28 است. بنابراین مشتریان نکول‌کننده‌ای که مدل به‌درستی شناسایی کرده، به طور متوسط سقف اعتبار پایین‌تری داشته‌اند.

از طرف دیگر، میانگین سقف اعتبار گروه FP برابر با 120801.28 است و به گروه TP نزدیک‌تر از TN است. این شباهت نشان می‌دهد بخشی از مشتریان خوش‌حساب که به اشتباه پرریسک شناخته شده‌اند، از نظر سقف اعتبار ویژگی‌هایی شبیه مشتریان واقعاً نکول‌کننده داشته‌اند.

گروه FN با میانگین 164669.34 به گروه مشتریان کم‌ریسک نزدیک‌تر است. در نتیجه، برخی مشتریان نکول‌کننده‌ای که مدل قادر به شناسایی آن‌ها نبوده است، از نظر سقف اعتبار ظاهری نسبتاً سالم‌تر داشته‌اند.

تحلیل وضعیت پرداخت اخیر. قوی‌ترین تفاوت بین چهار گروه در PAY_0 مشاهده می‌شود. میانگین این متغیر در گروه TP برابر با 1.27 است، در حالی که برای TN مقدار -0.41 به دست آمده است. این اختلاف نشان می‌دهد تأخیر در پرداخت ماه اخیر یکی از سیگنال‌های اصلی شناسایی نکول توسط مدل است.

میانگین PAY_0 در گروه FP برابر با 0.47 است؛ یعنی بخشی از مشتریان خوش‌حسابی که مدل به اشتباه پرریسک تشخیص داده، در سابقه اخیر خود رفتارهایی شبیه مشتریان دارای ریسک داشته‌اند.

مهم‌تر از آن، میانگین PAY_0 در گروه FN برابر با -0.36 و بسیار نزدیک به گروه TN است. بنابراین تعدادی از مشتریانی که در نهایت نکول کرده‌اند، در ماه اخیر تأخیر واضحی از خود نشان نداده‌اند. همین شباهت ظاهری به مشتریان کم‌ریسک یکی از توضیحات اصلی برای عدم شناسایی این گروه توسط مدل است.

تحلیل مبلغ پرداخت. میانگین PAY_AMT1 برای گروه TP برابر با 2327.98 و برای گروه TN برابر با 7433.20 است. بنابراین مشتریان نکول‌کننده‌ای که مدل به‌درستی تشخیص داده، به طور متوسط پرداخت ماهانه کمتری داشته‌اند. گروه FP با میانگین 1942.47 حتی پرداخت کمتری نسبت به گروه TP دارد و از این منظر کاملاً شبیه یک مشتری پرریسک ظاهر می‌شود. این موضوع بخشی از هشدارهای کاذب مدل را توضیح می‌دهد.


در مقابل، میانگین PAY_AMT1 در گروه FN حدود 5883.01 است و به مقدار گروه TN نزدیک‌تر است. بنابراین برخی مشتریان نکول‌کننده پیش از وقوع نکول، پرداخت نسبتاً مناسبی داشته‌اند و مدل از این رفتار به عنوان نشانه کم‌ریسک بودن استفاده کرده است.

تحلیل مبلغ صورت‌حساب. میانگین BILL_AMT1 برای گروه FN برابر با 60857.75 و حتی از میانگین گروه TN بیشتر است. این موضوع نشان می‌دهد مبلغ بالای صورت‌حساب به‌تنهایی برای تشخیص نکول کافی نیست. مقدار بدهی باید در ارتباط با سقف اعتبار، مبلغ پرداخت و سابقه تأخیر تفسیر شود.

گروه FP با میانگین 31198.24 کمترین مقدار را در میان چهار گروه دارد؛ بنابراین مدل نیز تصمیم خود را صرفاً بر اساس بزرگی صورت‌حساب اتخاذ نکرده است.

تحلیل سن. میانگین سن در تمام گروه‌ها در محدوده بسیار نزدیک 35 تا 37 سال قرار دارد. این هم‌پوشانی زیاد نشان می‌دهد AGE به‌تنهایی توان تفکیک محدودی برای تشخیص خطاهای مدل دارد و رفتار مالی و سابقه پرداخت نسبت به سن اطلاعات بسیار بیشتری در اختیار مدل قرار می‌دهند.

برای مشاهده مرکز توزیع، دامنه بین چارکی و داده‌های پرت، همان ویژگی‌ها با نمودار جعبه‌ای نیز مقایسه شدند.



شکل ۱۷: نمودارهای جعبه‌ای ویژگی‌های منتخب در چهار گروه خطای مدل XGBoost.

شکل ۱۷ نتایج نمودارهای چگالی را از منظر میانه و پراکندگی تأیید می‌کند. در LIMIT_BAL میانه گروه TN حدود ۱۷۰,۰۰۰ است، در حالی که میانه گروه‌های TP و FP در حوالی ۸۰,۰۰۰ قرار دارد. میانه گروه FN حدود ۱۳۰,۰۰۰ است و میان گروه پریسک و کم‌ریسک قرار می‌گیرد. این الگو مجدداً نشان می‌دهد FN از نظر توان اعتباری شباهت بیشتری به مشتریان سالم دارد.


در متغیر PAY_0 تفکیک واضح‌تری مشاهده می‌شود. میانه این متغیر در TP در حوالی ۲ قرار دارد، در حالی که برای TN و FN در حوالی ۰ است. گروه FP نیز از این نظر بین دو گروه اصلی قرار دارد. این نمودار تأیید می‌کند که تأخیر اخیر در

پرداخت نقش مهمی در تصمیم مدل داشته است.

نمودارهای PAY_AMT1 و BILL_AMT1 وجود تعداد زیادی داده پرت را نشان می‌دهند. مقادیر بسیار بزرگ در این ویژگی‌ها باعث می‌شوند میانگین به تنهایی نماینده کاملی از توزیع نباشد. بنابراین استفاده هم‌زمان از نمودارهای KDE و جعبه‌ای ضروری است؛ نمودار چگالی شکل کلی توزیع را نمایش می‌دهد، در حالی که نمودار جعبه‌ای میانه، پراکندگی و شدت مقادیر پرت را روشن می‌کند.

در AGE نیز میانه چهار گروه تقریباً یکسان است و مقدار آن در محدوده 34 تا 35 سال قرار دارد. این موضوع مجدداً قدرت تفکیک محدود سن را نسبت به ویژگی‌های رفتاری تأیید می‌کند.


برای برجسته کردن تفاوت میان دو گروه از نظر کسب‌وکار مهم‌تر، یعنی TP و FN، در شکل ۱۸ توزیع این دو گروه به صورت مستقیم مقایسه شده است. در این مقایسه، نزدیکی توزیع FN‌ها به مشتریان کم‌ریسک در ویژگی‌هایی مانند PAY_0 و LIMIT_BAL روشن‌تر دیده می‌شود. به عبارت دیگر، بخش مهمی از نکول‌های از دست‌رفته، نمونه‌هایی هستند که سیگنال‌های متداول ریسک را با شدت کمتر نشان می‌دهند و به همین دلیل در مرز تصمیم مدل قرار می‌گیرند.



شکل ۱۸: مقایسه مستقیم توزیع ویژگی‌های منتخب بین گروه‌های FN و TP.

برای آنکه اختلاف میان چهار گروه با مقیاس‌های متفاوت ویژگی‌ها قابل مقایسه باشد، میانگین ویژگی‌ها به صورت Z-score نرمال‌سازی و در شکل ۱۹ نمایش داده شد. این نقشه حرارتی نشان می‌دهد گروه TP در PAY_0 بالاتر از میانگین کلی و در PAY_AMT1 و LIMIT_BAL پایین‌تر از میانگین قرار دارد. در مقابل، گروه FN در PAY_0 الگویی نزدیک به TN و

در BILL_AMT1 مقداری بالاتر از میانگین نشان می‌دهد. بنابراین مشخصه اصلی FN ها صرفاً بدهی بالا نیست، بلکه ترکیب «بدهی قابل توجه همراه با رفتار پرداخت ظاهراً بهتر» است.



شکل ۱۹: نقشه حرارتی میانگین نرمال شده ویژگی‌های منتخب در چهار گروه خطای مدل.

۱.۸.۴. جمع‌بندی تحلیل خطاها

تحلیل هم‌زمان دو شکل نشان می‌دهد خطاهای مدل کاملاً تصادفی نیستند. گروه FP در چند ویژگی اصلی، از جمله سقف اعتبار پایین‌تر، پرداخت کمتر و سابقه تأخیر، به مشتریان TP شباهت دارد. بنابراین مدل از روی اطلاعات موجود دلایل قابل فهمی برای پرریسک دانستن این مشتریان داشته است، هرچند آن‌ها در نهایت نکول نکرده‌اند.

در نقطه مقابل، گروه FN در ویژگی‌هایی مانند PAY_0, LIMIT_BAL و PAY_AMT1 بیشتر به گروه TN شباهت دارد. این مشتریان پیش از نکول، نشانه‌های کلاسیک ریسک را با شدت کمتری بروز داده‌اند و به همین دلیل شناسایی آن‌ها دشوارتر بوده است.

از منظر کاربردی، این نتیجه نشان می‌دهد اتکا به یک نشانه مانند تأخیر آخرین ماه کافی نیست و برای شناسایی FN ها باید ترکیبی از رفتار چندماهه مشتری، روند بدهی، میزان استفاده از اعتبار و نسبت پرداخت به صورت حساب مورد توجه قرار گیرد.

۹.۴. اهمیت ویژگی‌ها و تفسیر مدل با SHAP

پس از تحلیل عملکرد کلی مدل، از روش SHAP برای بررسی نقش ویژگی‌ها در تصمیم‌های XGBoost استفاده شد [۱۴]. این روش بر پایه مقادیر شاپلی، سهم هر ویژگی را در جابه‌جایی خروجی مدل نسبت به مقدار پایه توضیح می‌دهد. در تحلیل سراسری، میانگین قدر مطلق SHAP برای هر ویژگی نشان می‌دهد آن ویژگی به طور متوسط چه اندازه در تصمیم‌های مدل نقش داشته است؛ علامت مقدار SHAP نیز جهت اثر را در یک پیش‌بینی مشخص نشان می‌دهد.

از آنجا که متغیرهای دسته‌ای در خط لوله پیش‌پردازش کدگذاری شده‌اند، نام‌هایی مانند PAY_0_2 نمایانگر یک ستون کدگذاری شده و مشخصاً وقوع یک وضعیت معین از PAY_0 هستند. بنابراین تفسیر این بخش در فضای ویژگی‌های پس از پیش‌پردازش انجام می‌شود و نباید نام ستون‌های کدگذاری شده با مقدار خام اولیه اشتباه گرفته شود.

ده ویژگی دارای بیشترین اهمیت در جدول ۱۷ ارائه شده‌اند.

جدول ۱۷: ده ویژگی مهم مدل بر اساس میانگین قدر مطلق SHAP.


رتبه	ویژگی	Mean SHAP
1	PAY_0_2	0.30202
2	PAY_2_2	0.12667
3	PAY_0_0	0.12632
4	LIMIT_BAL	0.12510
5	CREDIT_UTILIZATION	0.12253
6	PAY_AMT1	0.12003
7	BILL_AMT1	0.11506
8	PAY_3_2	0.09642
9	PAY_AMT2	0.09117
10	PAY_TO_BILL_RATIO	0.08551

مهم‌ترین یافته این جدول، حضور چندین متغیر مربوط به وضعیت پرداخت در رتبه‌های نخست است. ویژگی PAY_0_2 با فاصله قابل توجهی بیشترین میانگین قدر مطلق SHAP را دارد. همچنین PAY_2_2 و PAY_3_2 در میان ویژگی‌های مهم قرار گرفته‌اند. این نتیجه با تحلیل اکتشافی و تحلیل گروه‌های خطا سازگار است و نشان می‌دهد وضعیت تأخیر در ماه‌های اخیر نقش اساسی در ارزیابی ریسک دارد.


ویژگی LIMIT_BAL نیز در رتبه چهارم قرار دارد و نشان می‌دهد سقف اعتبار مستقل از سابقه پرداخت در تصمیم مدل نقش دارد. از سوی دیگر، CREDIT_UTILIZATION و PAY_TO_BILL_RATIO دو ویژگی مهندسی شده هستند که در میان ده ویژگی برتر قرار گرفته‌اند. این نتیجه نشان می‌دهد ترکیب متغیرهای خام و استخراج نسبت‌های مالی توانسته اطلاعاتی فراتر از استفاده مستقیم از ستون‌های اولیه در اختیار مدل قرار دهد.

حضور PAY_AMT1، PAY_AMT2 و BILL_AMT1 در میان ویژگی‌های مهم نیز نشان می‌دهد مدل علاوه بر وضعیت تأخیر، اندازه واقعی پرداخت و بدهی اخیر مشتری را در تصمیم خود وارد می‌کند. در مجموع، ساختار اهمیت ویژگی‌ها تأکید می‌کند که رفتار مالی اخیر مشتری نسبت به متغیرهای جمعیت‌شناختی نقش برجسته‌تری در پیش‌بینی نکول دارد.

شکل ۲۰ نمای Beeswarm مقادیر SHAP را نشان می‌دهد. در این نمودار، علاوه بر بزرگی اثر، جهت اثر و پراکندگی آن در کل نمونه‌های آزمون قابل مشاهده است؛ بنابراین ممکن است یک ویژگی در بعضی مشتریان ریسک را افزایش و در برخی دیگر کاهش دهد. شکل ۲۱ نیز همان اطلاعات را به صورت خلاصه و بر اساس میانگین قدر مطلق اثر رتبه‌بندی می‌کند.




شکل ۲۰: نمودار Beeswarm مقادیر SHAP برای مدل XGBoost.



شکل ۲۱: رتبه‌بندی سراسری ویژگی‌ها بر اساس میانگین قدر مطلق SHAP.

برای بررسی رفتار غیرخطی برخی ویژگی‌های مهم، نمودارهای وابستگی SHAP در شکل ۲۲ رسم شدند. این نمودارها نشان می‌دهند اثر یک ویژگی بر خروجی مدل لزوماً خطی نیست و بسته به ناحیه مقدار ویژگی و برهم‌کنش با سایر متغیرها می‌تواند تغییر کند. در تفسیر محور افقی باید توجه داشت که نمودارها بر مبنای ماتریس ویژگی‌های پس از پیش‌پردازش ساخته شده‌اند؛ از این رو، تأکید اصلی بر جهت و شکل رابطه است، نه بازخوانی همه مقادیر محور به عنوان مقیاس خام اولیه.



شکل ۲۲: نمودارهای وابستگی SHAP برای بررسی اثرهای غیرخطی ویژگی‌های منتخب.

۱۰.۴. مطالعه موردی خطاهای مدل با SHAP


برای درک بهتر تصمیم مدل در سطح نمونه، چند نمونه خطادار با SHAP به صورت محلی بررسی شدند. در یکی از نمونه‌های FN با شاخص 1836، برخی ویژگی‌ها مانند BILL_AMT1 با مقدار $SHAP=+0.1878$ و AVG_PAY_AMT با مقدار $+0.1214$ مدل را به سمت پیش‌بینی نکول سوق داده‌اند. در مقابل، ویژگی مربوط به دسته PAY_0_2 با مقدار -0.1258 و PAY_TO_BILL_RATIO با مقدار -0.1172 مدل را به سمت پیش‌بینی عدم نکول هدایت کرده‌اند. این نمونه نشان می‌دهد مشتری دارای سیگنال‌های متناقض بوده است و مجموع سیگنال‌های کم‌ریسک باعث شده مدل نتواند نکول واقعی را شناسایی کند.

در یک نمونه FP با شاخص 2012، ویژگی PAY_0_2 با مقدار بسیار بزرگ $SHAP=+1.1910$ مدل را به شدت به سمت نکول سوق داده است. همچنین PAY_2_2، PAY_3_2، PAY_4_2 و PAY_5_2 همگی اثر مثبت در جهت پیش‌بینی نکول داشته‌اند. بنابراین این مشتری در چند ماه متوالی سابقه‌ای شبیه مشتریان پرریسک داشته و مدل با توجه به این سابقه، پیش‌بینی نکول را منطقی دانسته است؛ هرچند برچسب واقعی او عدم نکول بوده است.

این دو مطالعه موردی نشان می‌دهند خطاهای مدل الزاماً نتیجه یک ویژگی منفرد نیستند؛ بلکه حاصل رقابت میان چند سیگنال موافق و مخالف هستند. تحلیل محلی SHAP از این جهت مفید است که مشخص می‌کند چرا دو مشتری با ویژگی‌های ظاهراً مشابه ممکن است خروجی متفاوتی دریافت کنند.

شکل ۲۳: نمودار آشناری این دو نمونه را نشان می‌دهد. در هر نمودار، اثر ویژگی‌هایی که خروجی را به سمت نکول می‌برند

در برابر اثر ویژگی‌هایی که پیش‌بینی را به سمت عدم نکول می‌کشاند دیده می‌شود. این نمایش محلی مکمل تحلیل سراسری است؛ زیرا یک ویژگی با اهمیت متوسط در کل داده ممکن است برای یک مشتری خاص نقش تعیین‌کننده داشته باشد.



شکل ۲۳: تحلیل محلی دو نمونه خطای مدل با نمودار آشنایی SHAP.

۱۱.۴. جمع‌بندی بخش مدل‌سازی و پاسخ به سؤال پژوهش

نتایج این بخش نشان داد که سابقه مالی و رفتار بازپرداخت شش‌ماهه مشتریان دارای اطلاعات کافی برای ایجاد یک مدل پیش‌بینی‌کننده نکول است. در میان پنج الگوریتم بررسی‌شده، XGBoost با $ROC-AUC=0.7810$ و $PR-AUC=0.5634$ و $F1=0.5354$ و $Recall=0.6237$ بهترین عملکرد کلی را ارائه کرد.

در عین حال، نتایج نشان داد هیچ مدل کاملی وجود ندارد و انتخاب مدل با نوع خطای قابل‌قبول ارتباط مستقیم دارد. LightGBM اندکی Recall بالاتری ارائه کرد، در حالی که رگرسیون لجستیک و جنگل تصادفی Accuracy بیشتری داشتند. با این حال، XGBoost از نظر معیار اصلی PR-AUC و همچنین ROC-AUC و F1 برتری داشت؛ از این رو به عنوان مدل نهایی انتخاب شد.

تحلیل FP و FN نیز نشان داد که مشتریان اشتباه پیش‌بینی‌شده دارای الگوهای مشخصی هستند. مشتریان FP در بسیاری از ویژگی‌ها واقعاً به گروه پرریسک شباهت دارند، در حالی که مشتریان FN بخشی از نشانه‌های ظاهری مشتریان کم‌ریسک را دارند. بنابراین خطاهای مدل را نمی‌توان صرفاً به ضعف تصادفی الگوریتم نسبت داد؛ بخشی از آن‌ها ناشی از هم‌پوشانی واقعی ساختار ویژگی‌های دو کلاس است.

در نهایت، تحلیل SHAP نشان داد وضعیت پرداخت ماه‌های اخیر، سقف اعتبار، میزان استفاده از اعتبار، مبالغ پرداخت و

صورت حساب و نسبت پرداخت به بدهی از مهم‌ترین عوامل دخیل در تصمیم مدل هستند. این نتیجه به سؤال اصلی پروژه پاسخ می‌دهد: سابقه پرداخت و رفتار مالی گذشته مشتریان می‌تواند برای شناسایی ریسک نکول آینده مورد استفاده قرار گیرد، اما کیفیت تصمیم تنها به مقدار بدهی یا ویژگی‌های جمعیت‌شناختی وابسته نیست و الگوی ترکیبی رفتار بازپرداخت در طول زمان اهمیت بیشتری دارد.

۵. نتیجه‌گیری

هدف این پروژه بررسی این پرسش بود که آیا می‌توان با استفاده از اطلاعات جمعیت‌شناختی و به‌ویژه سابقه شش‌ماهه رفتار مالی مشتریان، ریسک نکول در ماه بعد را پیش‌بینی کرد. برای پاسخ به این پرسش، یک فرایند کامل از شناخت داده و تحلیل اکتشافی تا مقایسه پیش‌پردازش، آموزش چند خانواده مدل، تنظیم ابرپارامترها، ارزیابی چندمعیاره، تحلیل خطا و تفسیرپذیری اجرا شد. در مرحله شناخت داده مشخص شد که مسئله با سه ویژگی ساختاری مهم مواجه است: نخست، توزیع بسیاری از متغیرهای مالی به‌شدت راست‌چوله و دارای داده‌های پرت است؛ دوم، متغیرهای صورت حساب و وضعیت پرداخت در ماه‌های متوالی وابستگی زمانی و همبستگی قابل توجهی دارند؛ و سوم، کلاس هدف نامتوازن است و تنها حدود 22.1% مشاهدات در کلاس نکول قرار می‌گیرند. این سه ویژگی مستقیماً بر انتخاب روش‌های پیش‌پردازش و معیارهای ارزیابی اثر گذاشتند.

در فاز پیش‌پردازش، روش‌های مختلف به صورت مقایسه‌ای ارزیابی شدند. آزمایش مقادیر گم‌شده مصنوعی نشان داد حذف ردیف‌ها نسبت به روش‌های جای‌گذاری ضعیف‌تر است و KNN Imputation بالاترین ROC-AUC را در آن آزمایش ثبت کرد. در مقیاس‌بندی، StandardScaler و RobustScaler عملکرد بسیار نزدیکی داشتند و با اختلاف اندک انتخاب شد. مهندسی چهار ویژگی رفتاری تنها بهبود جزئی در مدل خطی ایجاد کرد، اما دو ویژگی CREDIT_UTILIZATION و PAY_TO_BILL_RATIO بعداً در تحلیل اهمیت ویژگی‌ها نیز ظاهر شدند. محدودسازی داده‌های پرت مبتنی بر IQR مقادیر ROC-AUC و PR-AUC را بهبود داد. در مسئله عدم تعادل نیز روش بدون نمونه‌برداری بیشترین PR-AUC را داشت، در حالی که وزن‌دهی و روش‌های نمونه‌برداری Recall را به طور محسوسی افزایش دادند. این نتیجه نشان داد که انتخاب پیش‌پردازش باید با هدف تصمیم‌گیری و هزینه خطاها هماهنگ باشد و نمی‌توان یک روش را صرفاً بر اساس یک معیار برتر دانست.

۱.۵. پاسخ به پرسش‌های پژوهش

کدام الگوهای مالی و رفتاری بیشترین ارتباط را با نکول دارند؟ تحلیل اکتشافی، تحلیل گروه‌های خطا و SHAP به شکل هم‌راستا نشان دادند که سابقه تأخیر در پرداخت، به‌ویژه وضعیت ماه‌های اخیر، مهم‌ترین سیگنال ریسک در داده است. پس از آن، سقف اعتبار، میزان استفاده از اعتبار، مبلغ پرداخت و صورت حساب و نسبت پرداخت به بدهی نقش قابل توجهی دارند. در مقابل، سن در تحلیل گروه‌های خطا قدرت تفکیک محدودی نشان داد. بنابراین رفتار مالی اخیر برای پیش‌بینی نکول از ویژگی‌های جمعیت‌شناختی ساده اطلاعات بیشتری فراهم می‌کند.

کدام مدل بهترین عملکرد را ارائه می‌کند؟ پنج الگوریتم درخت تصمیم، جنگل تصادفی، رگرسیون لجستیک، XGBoost و LightGBM پس از تنظیم ابرپارامترها مقایسه شدند. درخت تصمیم بیشترین سود را از تنظیم پارامترها برد، اما همچنان پایین‌ترین PR-AUC را میان مدل‌های نهایی داشت. جنگل تصادفی عملکردی پایدار و رقابتی ارائه کرد. رگرسیون لجستیک بیشترین Accuracy را میان مدل‌های تنظیم‌شده داشت و نشان داد یک مدل خطی ساده نیز می‌تواند خط مبنای معناداری فراهم کند. LightGBM با $\text{Recall}=0.6259$ بالاترین فراخوانی را ثبت کرد. با این حال، XGBoost با $\text{PR-AUC}=0.5634$ ، $\text{ROC-AUC}=0.7810$ و $\text{Recall}=0.6237$ و $\text{F1}=0.5354$ بهترین تعادل کلی را میان معیارهای اصلی ایجاد کرد و به عنوان مدل نهایی انتخاب شد.

مدل در چه نمونه‌هایی بیشتر دچار خطا می‌شود؟ در مجموعه آزمون، 827 مشتری نکول‌کننده به‌درستی شناسایی شدند و 499 مشتری نکول‌کننده در گروه FN قرار گرفتند. مقایسه این گروه با TP نشان داد FN ها به طور متوسط سقف اعتبار بالاتر، تأخیر اخیر کمتر و مبلغ پرداخت اخیر بیشتری دارند. به بیان دیگر، بخشی از مشتریانی که نهایتاً نکول می‌کنند پیش از وقوع نکول ظاهری شبیه‌تر به مشتریان کم‌ریسک دارند و همین هم‌پوشانی ساختاری تشخیص آن‌ها را دشوار می‌کند. در مقابل، بسیاری از FP ها از نظر سقف اعتبار پایین، پرداخت کمتر یا سابقه تأخیر واقعاً به مشتریان پرریسک شباهت دارند؛ بنابراین هشدار کاذب مدل نیز در بسیاری موارد از الگوی قابل‌فهمی ناشی می‌شود.

۲.۵. پیامدهای کاربردی

نتایج نشان می‌دهد استفاده از مدل صرفاً به صورت یک برچسب «پرریسک/کم‌ریسک» کافی نیست. در کاربرد واقعی، هزینه FN و FP برابر نیست: از دست دادن یک نکول‌کننده می‌تواند زیان اعتباری مستقیم ایجاد کند، در حالی که هشدار کاذب ممکن است به رد یک مشتری مناسب و از دست رفتن فرصت درآمدی منجر شود. بنابراین مدل XGBoost در این پروژه باید به عنوان یک ابزار پشتیبان تصمیم و غربالگری اولیه تفسیر شود، نه جایگزین کامل سیاست اعتباری مؤسسه. انتخاب آستانه تصمیم نیز می‌تواند بسته به هزینه واقعی دو نوع خطا تغییر کند.

۳.۵. محدودیت‌ها و مسیرهای ادامه کار

این مطالعه بر یک مجموعه داده تاریخی مربوط به تایوان و سال 2005 استوار است و تنها شش ماه سابقه مالی را پوشش می‌دهد. در نتیجه، قابلیت تعمیم نتایج به بانک‌ها، کشورها و دوره‌های زمانی دیگر بدون اعتبارسنجی خارجی تضمین‌شده نیست. همچنین متغیرهایی مانند درآمد، شغل، اطلاعات اقتصاد کلان و سابقه اعتباری خارج از این دوره در داده وجود ندارند. بنابراین برخی نکول‌ها ممکن است ناشی از عواملی باشند که مدل اساساً آن‌ها را مشاهده نمی‌کند.

برای ادامه این پروژه، چند مسیر از نظر فنی و کاربردی قابل پیگیری است. نخست، می‌توان به جای استفاده ثابت از آستانه 0.5، آستانه تصمیم را بر اساس هزینه مالی FP و FN تنظیم کرد. دوم، کیفیت احتمال نکول را می‌توان با روش‌های کالیبراسیون و معیارهایی مانند Brier Score بررسی کرد. سوم، اعتبارسنجی روی یک یا چند دیتاست اعتباری دیگر می‌تواند میزان تعمیم‌پذیری یافته‌ها را روشن کند. چهارم، پایداری توضیحات SHAP در چند اجرای مدل و نیز تفاوت عملکرد میان

گروه‌های جمعیت‌شناختی می‌تواند به عنوان گام بعدی در تحلیل تفسیرپذیری و عدالت مدل بررسی شود. در نهایت، وجود سابقه شش‌ماهه امکان طراحی ویژگی‌های روندی غنی‌تر یا استفاده از مدل‌های زمانی را نیز فراهم می‌کند. در مجموع، پاسخ اصلی پروژه مثبت است: سابقه پرداخت و رفتار مالی گذشته مشتریان اطلاعات معناداری برای پیش‌بینی نکول آینده فراهم می‌کند. با این حال، ارزش اصلی مدل زمانی آشکار می‌شود که علاوه بر قدرت پیش‌بینی، نوع خطاها، معیار ارزیابی و قابلیت توضیح تصمیم‌ها نیز در کنار یکدیگر در نظر گرفته شوند.

- [1] UCI Machine Learning Repository, “Default of Credit Card Clients,” Dataset 350. doi: 10.24432/C55S3H.
- [2] I.-C. Yeh and C.-H. Lien, “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients,” *Expert Systems with Applications*, vol. 36, no. 2, pp. 2473–2480, 2009. doi: 10.1016/j.eswa.2007.12.020.
- [3] S. Hamori, M. Kawai, T. Kume, Y. Murakami, and C. Watanabe, “Ensemble Learning or Deep Learning? Application to Default Risk Analysis,” *Journal of Risk and Financial Management*, vol. 11, no. 1, article 12, 2018. doi: 10.3390/jrfm11010012.
- [4] T. M. Alam, K. Shaukat, I. A. Hameed, et al., “An Investigation of Credit Card Default Prediction in the Imbalanced Datasets,” *IEEE Access*, vol. 8, pp. 201173–201198, 2020. doi: 10.1109/ACCESS.2020.3033784.
- [5] Y. Chen and R. Zhang, “Research on Credit Card Default Prediction Based on k-Means SMOTE and BP Neural Network,” *Complexity*, vol. 2021, article 6618841, 2021. doi: 10.1155/2021/6618841.
- [6] R. Bhandary and B. K. Ghosh, “Credit Card Default Prediction: An Empirical Analysis on Predictive Performance Using Statistical and Machine Learning Methods,” *Journal of Risk and Financial Management*, vol. 18, no. 1, article 23, 2025. doi: 10.3390/jrfm18010023.
- [7] K. M. Sujon et al., “Accuracy, precision, recall, F1-score, or MCC? Empirical evidence from advanced statistics, ML, and XAI for evaluating business predictive models,” *Journal of Big Data*, 2025. doi: 10.1186/s40537-025-01313-4.
- [8] L. Lin and Y. Wang, “SHAP Stability in Credit Risk Management: A Case Study in Credit Card Default Model,” arXiv:2508.01851, 2025.
- [9] P. Snel and S. van Otterloo, “Practical bias correction in neural networks: a credit default prediction case study,” *Computers and Society Research Journal*, vol. 3, 2022. doi: 10.54822/BEWO3288.
- [10] I. Emmanuel, Y. Sun, and Z. Wang, “A machine learning-based credit risk prediction engine system using a stacked classifier and a filter-based feature selection method,” *Journal of Big Data*, vol. 11, article 23, 2024.

- [11] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [12] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016.
- [13] G. Ke et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [14] S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.